

Redes Neuronales de Picos (SNN)

Fundamentos, arquitectura y aplicaciones actuales

Preparación CoNallSI 2026 · 25 de June de 2026 · Marco teórico del paper LIF climático

Este informe provee una descripción técnica completa de las Spiking Neural Networks (SNN): su origen histórico, fundamentos matemáticos, arquitectura, esquemas de codificación, reglas de aprendizaje, hardware neuromórfico y aplicaciones actuales en detección de anomalías y series temporales. Sirve como marco teórico riguroso para el paper de detección de eventos climáticos extremos con modelo LIF simplificado.

Índice del informe
• Sección 1 — Las tres generaciones de redes neuronales: por qué existen las SNN
• Sección 2 — El modelo LIF: Lapicque (1907) a la computación moderna
• Sección 3 — Arquitectura de una SNN: componentes y operación
• Sección 4 — Codificación de información en spikes
• Sección 5 — Variantes del modelo neuronal: de LIF a GLIF
• Sección 6 — Aprendizaje en SNN: STDP y surrogate gradients
• Sección 7 — Hardware neuromórfico: Loihi, Xylo, TrueNorth
• Sección 8 — Aplicaciones actuales: anomalía, series temporales, sensores
• Sección 9 — El modelo LIF simplificado de tu paper: posición en el campo
• Sección 10 — Referencias

1. Las tres generaciones de redes neuronales

Wolfgang Maass formalizó en 1997 la taxonomía que organiza la historia de las redes neuronales artificiales en tres generaciones, cada una caracterizada por el tipo de señal que sus neuronas procesan y transmiten. Esta taxonomía es el marco de referencia obligatorio para posicionar las SNN en el campo.

Generación	Modelo de neurona	Señal transmitida	Potencia computacional	Ejemplos
Primera (1943–1980s)	McCulloch-Pitts (1943), Perceptrón	Binaria estática: 0 o 1	Funciones booleanas. Limitada a problemas linealmente separables.	Perceptrón, redes AND/OR/NOT
Segunda (1986–presente)	Neurona sigmoideal, ReLU	Valor continuo en [0,1] o R. Sin temporalidad.	Aproximador universal de funciones. Dominante en la industria actual.	MLP, CNN, LSTM, Transformer, GPT
Tercera (1997–presente)	Leaky Integrate-and-Fire (LIF) y variantes	Spikes: pulsos binarios con temporalidad explícita.	Maass (1997): computacionalmente más potente que la 2da generación con menos neuronas. Ventaja en funciones dependientes del tiempo.	SNN, LSM, redes neuromórficas

Resultado central de Maass (1997): una función concreta biológicamente relevante puede ser computada por una SOLA neurona de pico con parámetros biológicamente razonables, pero requiere cientos de unidades ocultas en una red sigmoideal equivalente. La clave está en que el tiempo del spike porta información — algo que las redes de segunda generación descartan completamente.

2. El modelo LIF: de Lapicque (1907) a la computación moderna

2.1 El origen: Lapicque 1907

Louis Lapicque publica en 1907 'Recherches quantitatives sur l'excitation électrique des nerfs traitée comme une polarisation'. Usando electrofisiología de nervios de rana, propone que la membrana neuronal se comporta como un circuito RC: una resistencia en paralelo con un capacitor. La corriente eléctrica carga el capacitor (potencial de membrana); cuando llega al umbral, se genera un potencial de acción (spike) y el potencial se resetea. Este modelo es el Integrate-and-Fire original.

Brunel y van Rossum (2007) y Abbott (1999) documentan cómo este paper de 1907 anticipa conceptos que la neurociencia computacional redescubriría décadas después: la constante de tiempo de la membrana ($\tau_m = RC$), la existencia de un umbral, y el reset post-spike.

2.2 La ecuación fundamental del LIF

El modelo LIF moderno (Gerstner et al., 2014) se describe con una EDO de primer orden lineal. Esta es la ecuación central de todo el campo:

$$\tau_m \cdot (dV/dt) = -(V(t) - V_{rest}) + R \cdot I(t)$$

Con condición de disparo y reset:

$$\text{Si } V(t) \geq V_{threshold} \rightarrow \text{emite spike} \rightarrow V(t) := V_{reset}$$

Parámetro	Símbolo	Significado biológico	Valor típico
Potencial de membrana	$V(t)$	Voltaje eléctrico de la célula en el tiempo t	Variable de estado
Potencial en reposo	V_{rest}	Voltaje basal cuando no hay estímulo	-65 mV (bio) / 0 (normalizado)
Constante de tiempo	τ_m	Velocidad de decaimiento del potencial. $\tau_m = RC$	10–30 ms (bio)
Resistencia de membrana	R	Resistencia eléctrica de la membrana	Escala la corriente de entrada
Corriente de entrada	$I(t)$	Suma de corrientes sinápticas entrantes	Variable de entrada
Umbral de disparo	$V_{threshold}$	Nivel de potencial que dispara un spike	-55 mV (bio) / 1 (normalizado)
Potencial de reset	V_{reset}	Valor al que cae el potencial tras un spike	-70 mV (bio) / 0 (normalizado)

2.3 Período refractario y período de gracia

Tras emitir un spike, la neurona biológica entra en un período refractario durante el cual no puede disparar de nuevo, independientemente de la corriente entrante. El período refractario absoluto (~2ms en neuronas biológicas) previene que una neurona dispare dos spikes tan seguidos que sean indistinguibles. El período refractario relativo (varios ms) aumenta el umbral temporalmente, haciendo más difícil el disparo. En implementaciones de software, se modela con un contador de pasos post-spike durante el cual V se

fija en V_{reset} sin procesar entradas.

2.4 La variabilidad neuronal: Stein (1965, 1967) y Gerstein-Mandelbrot (1964)

Una neurona biológica real no dispara con intervalos perfectamente regulares bajo corriente constante — exhibe variabilidad estocástica. Stein (1965) propone modelar la actividad de picos como un proceso puntual con corriente de entrada aleatoria, analizando la distribución de intervalos entre spikes (ISI). Stein (1967) extiende esto a modelos con múltiples fuentes de ruido. Gerstein y Mandelbrot (1964) proponen el 'random walk model': el potencial de membrana realiza una caminata aleatoria hasta cruzar el umbral — el primer modelo estocástico de actividad neuronal. Estos trabajos son la base matemática del análisis de variabilidad que diferencia el LIF determinístico (tu modelo simplificado) del LIF estocástico (LIF+ruido).

3. Arquitectura de una SNN: componentes y operación

Una SNN completa no es solo un conjunto de neuronas LIF — es una arquitectura de procesamiento de información asíncrono con varios componentes interactuantes.

3.1 Componentes estructurales

- **Capa de entrada / codificación:** convierte datos del mundo real (señales continuas, imágenes, series temporales) en trenes de spikes. Este es uno de los problemas más activos del campo — ver Sección 4.
- **Neuronas LIF (u otras variantes):** integran spikes entrantes, decaen, y disparan cuando alcanzan el umbral. Cada conexión sináptica tiene un peso w_{ij} que pondera el spike recibido.
- **Sinapsis con dinámica temporal:** los spikes no se transmiten instantáneamente — la corriente sináptica tiene su propia constante de tiempo τ_s que determina cuánto dura el efecto de cada spike en el potencial postsináptico.
- **Capa de salida / decodificación:** convierte el tren de spikes de salida en una decisión o valor. Las dos estrategias principales son contar spikes en una ventana temporal (rate decoding) o medir el tiempo al primer spike (temporal decoding).

3.2 La diferencia fundamental con las ANN de segunda generación

En una ANN convencional: la información es el VALOR de la activación (un número real). La operación fundamental es la multiplicación: $y = W \cdot x + b$, seguida de una no-linealidad. En una SNN: la información está en EL TIEMPO y LA FRECUENCIA de los spikes (pulsos binarios). La operación fundamental es una MAC (Multiply-Accumulate) solo cuando llega un spike — si no hay spike, no hay cómputo. Esto genera eficiencia energética extrema en hardware especializado: 0 operaciones cuando la red está 'en silencio'.

3.3 Por qué las SNN son más eficientes energéticamente

En una ANN densa, todas las neuronas computan en cada paso de tiempo, independientemente de si hay señal. En una SNN, una neurona solo 'gasta energía' cuando recibe o emite un spike. En señales esparsas (como datos de sensores en reposo), la actividad de spikes es muy baja, y el consumo energético cae proporcionalmente. Los papers de hardware (Loihi, TrueNorth, Xylo) reportan reducciones de 1 a 3 órdenes de magnitud en consumo respecto a GPU equivalente.

- **Vacuum Spiker (Vázquez et al., 2025):** en detección de anomalías en series temporales, la red SNN alcanza baja tasa de falsas alarmas con alta eficiencia computacional precisamente porque solo procesa cuando hay actividad.
- **Detección de objetos rápidos (Ziegler et al., 2024):** SNN sobre hardware neuromórfico corre en tiempo real con latencia y consumo inviables para GPU convencional en el mismo task.

4. Codificación de información en spikes

El problema de cómo representar una señal continua (temperatura, presión, pixel) como un tren de spikes es uno de los más fundamentales del campo. Existen múltiples esquemas con trade-offs distintos.

Esquema	Mecanismo	Ventajas	Desventajas	Aplicación típica
Rate coding (codificación por tasa)	El valor del estímulo determina la frecuencia de spikes en una ventana temporal. Mayor valor → más spikes por segundo.	Robusto al ruido. Simple de implementar y decodificar.	Lento: requiere ventana temporal larga para estimar la tasa. Descarta información temporal fina.	Clasificación de imágenes. Tu modelo LIF: temperatura alta → más corriente → más spikes.
Temporal coding (codificación temporal)	La información está en el tiempo exacto de cada spike. El primer spike en llegar tiene el valor más alto.	Ultra-rápido: una sola ronda de spikes puede codificar toda una imagen.	Muy sensible al ruido. Difícil de entrenar.	Visión de alta velocidad. Procesamiento de eventos.
Phase coding	El tiempo del spike se mide relativo a una oscilación de referencia (theta rhythm cerebral).	Permite codificación de múltiples variables simultáneas.	Requiere oscilador de referencia. Complejo.	Navegación espacial. Modelos de hipocampo.
Burst coding	La información está en el número de spikes en una ráfaga rápida, no en la tasa sostenida.	Compromiso entre rate y temporal coding.	Difícil de separar bursts de actividad sostenida.	Corteza sensorial. Robótica con sensores táctiles.
Population coding	Múltiples neuronas con umbrales/preferencias distintos codifican juntas un valor continuo.	Alta resolución. Robusto a falla de neuronas individuales.	Requiere muchas neuronas.	Sensores neuromórficos. Tu modelo con múltiples variables climáticas.

5. Variantes del modelo neuronal: de LIF a GLIF

El LIF es el punto de partida, pero la literatura ha generado una familia de variantes con mayor fidelidad biológica o mayor expresividad computacional. Conocer esta jerarquía es importante para justificar por qué tu paper usa el LIF y no una variante más compleja.

Modelo	Ecuación característica	Qué agrega sobre LIF	Uso típico
IF (Integrate-and-Fire) No-leaky	$\tau \cdot dV/dt = R \cdot I(t)$ (sin término de decaimiento)	Sin decaimiento: integra perfectamente. El potencial nunca cae solo.	Baseline teórico. No es biológicamente realista.
LIF (Leaky I-F) Lapicque 1907	$\tau \cdot dV/dt = -(V - V_{rest}) + R \cdot I(t)$	Decaimiento exponencial hacia V_{rest} . Balance entre integración y olvido.	Punto de partida estándar. Tu modelo.
ELIF (Exponential LIF)	Agrega término exponencial $\Delta T \cdot \exp((V - V_T)/\Delta T)$ cerca del umbral	Captura la dinámica de inicio del spike más fielmente. Umbral 'blando'.	Modelos de corteza. Mayor precisión en timing.
AdEx (Adaptive Exponential)	ELIF + variable de adaptación w : $\tau_w \cdot dw/dt = a(V - E_L) - w$	Modela adaptación de frecuencia: la neurona dispara menos con el tiempo bajo estímulo constante.	Acomodación neuronal. Modelado de tipos de neuronas corticales.
GLIF (Generalized LIF)	LIF + umbral adaptativo + reset adaptativo + corriente de after-spike	Ajustable a múltiples tipos de neuronas mediante parámetros. Familia unificada.	Modelado de Blue Brain Project. Ajuste a datos de patch-clamp.
Izhikevich (2003)	$dv/dt = 0.04v^2 + 5v + 140 - u + I$; $du/dt = a(bv - u)$; con reset condicional	Captura 20+ tipos de comportamiento neuronal (bursting, chattering, etc.) con solo 4 parámetros.	Redes de gran escala con diversidad de tipos neuronales.
HH (Hodgkin-Huxley 1952)	Sistema de 4 EDOs acopladas con canales iónicos de Na^+ , K^+ , Cl^-	Máxima fidelidad biológica. Modelo de referencia de la neurociencia.	Análisis de canales iónicos. Demasiado costoso para redes grandes.

Para tu paper: el LIF es la elección correcta y justificable. Las variantes más complejas (AdEx, GLIF, HH) agregan fidelidad biológica que no es necesaria para un detector de eventos. El LIF captura el mecanismo esencial (integración temporal + decaimiento + umbral) con la mínima complejidad implementable. Esto se declara explícitamente como elección metodológica, no como limitación.

6. Aprendizaje en SNN: STDP y surrogate gradients

El entrenamiento de SNN es el problema técnico más desafiante del campo, precisamente porque los spikes son no diferenciables (son funciones escalón) y el backpropagation clásico no puede aplicarse directamente.

6.1 STDP — Spike-Timing Dependent Plasticity

STDP es la regla de aprendizaje biológica: la modificación de la sinapsis entre dos neuronas depende del orden relativo y diferencia temporal de sus spikes. Si la neurona presináptica dispara ANTES que la postsináptica ($A \rightarrow B$), la sinapsis se fortalece (LTP: Long-Term Potentiation). Si A dispara DESPUÉS que B, se debilita (LTD: Long-Term Depression). La regla matemática es:

$$\Delta w = A_+ \cdot \exp(-\Delta t / \tau_+) \text{ si } \Delta t > 0 \text{ (LTP)}$$

$$\Delta w = -A_- \cdot \exp(\Delta t / \tau_-) \text{ si } \Delta t < 0 \text{ (LTD)}$$

STDP es puramente local (no requiere información global) y sin supervisión. Es biológicamente plausible pero difícil de escalar a tareas complejas porque no hay garantía de convergencia a una solución óptima.

6.2 Surrogate Gradient Learning

El estado del arte en entrenamiento de SNN (Neftci et al., 2019) usa 'surrogate gradients': reemplaza la función escalón no-diferenciable del spike por una función suave durante el backpropagation, pero usa la función escalón real durante el forward pass. Esto permite aplicar SGD (Stochastic Gradient Descent) estándar. Los resultados en clasificación de imágenes con datasets estándar (MNIST, CIFAR-10, DVS-CIFAR10) son comparables a ANN equivalentes con menor consumo energético.

- **Para tu paper:** el modelo LIF simplificado de una neurona NO necesita aprendizaje. Los parámetros (τ , umbral, pesos de las variables climáticas) se ajustan manualmente o por grid search — que es metodológicamente válido y mucho más simple. El paper de Maass (1997) mismo usa modelos sin aprendizaje para demostrar propiedades computacionales.

7. Hardware neuromórfico: Loihi, Xylo, TrueNorth

Las SNN son especialmente valiosas cuando se ejecutan en hardware neuromórfico especializado, diseñado para procesar spikes nativamente en lugar de emularlos sobre GPU. Estos chips implementan físicamente las dinámicas de la membrana.

Chip	Fabricante	Neuronas	Consumo	Características clave
TrueNorth	IBM (2014)	4096 cores 256 neuronas c/u = 1M neuronas	~70 mW total ~26 fJ/spike	Sin aprendizaje on-chip. Primera demostración de escala masiva. Clasificación en tiempo real con consumo de batería de celular.
Loihi / Loihi 2	Intel (2018/2021)	128 cores (Loihi) 2.3M sinapsis Loihi2: 1M neuronas	~1 mW por core	Aprendizaje on-chip con STDP. Programable. Usado en papers de anomaly detection, robótica, optimización.
Xylo	SynSense (2022)	Hasta 1000 neuronas por chip	Microwatts en edge	Diseñado para edge/IoT. Ideal para sensores ambientales. Paper de detección de RFI (Ziegler 2024) lo usa.
BrainScaleS	Heidelberg (2022)	500 neuronas analógicas	~1W	Hardware analógico: más rápido que tiempo real biológico (x1000). Para investigación de plasticidad.
DYNAP-SE2	SynSense	4096 neuronas analógicas	Ultra-bajo consumo	Procesamiento de señales sensoriales en tiempo real. Audición neuromórfica.

Para tu paper: no usás hardware neuromórfico — simulás el LIF en Python (software). El hardware se menciona en el marco teórico como 'la dirección hacia donde apunta la tecnología' y en trabajo futuro como 'el modelo propuesto podría implementarse en Loihi/Xylo para monitoreo en tiempo real de bajo consumo'. Eso le da perspectiva tecnológica sin requerir que tengas el hardware.

8. Aplicaciones actuales: donde las SNN están resolviendo problemas reales

Las SNN pasaron de ser modelos teóricos a tener aplicaciones industriales y científicas concretas. Las áreas donde muestran ventajas claras sobre ANN convencionales son aquellas con datos temporales, sensores de bajo consumo, y requerimientos de tiempo real.

8.1 Detección de anomalías en series temporales

Esta es el área más directamente relevante para tu paper. Las SNN son naturalmente adecuadas para series temporales porque el tiempo es una dimensión nativa de su operación, no algo que hay que simular.

- **Vacuum Spiker (Vázquez et al., 2025)**: SNN de una sola neurona de salida para detección de anomalías en series temporales multivariadas. Logra baja tasa de falsas alarmas con alta eficiencia. Directamente comparable a tu propuesta.
- **EONS (arXiv:2510.20997)**: clasificación binaria en series temporales multivariadas con neurona de salida única. Aplicado a detección de fuentes de radiación gamma y detección de convulsiones en EEG. Muestra que una arquitectura SNN mínima puede resolver problemas de detección complejos.
- **Detección de ciberataques en vehículos (Jaoudi et al., 2020)**: autoencoder convertido a SNN para detectar ataques en bus CAN de automóviles, logrando performance comparable a ANN con fracción del consumo energético.
- **Arritmias cardíacas (Bauer et al., 2019)**: SNN recurrente en procesador neuromórfico personalizado para detección en tiempo real de anomalías en ECG. Primer deployment wearable de SNN para monitoreo médico continuo.

8.2 Sensores ambientales neuromórficos

Una línea emergente en 2025-2026 aplica los principios LIF directamente en hardware de sensores, creando 'sensores que procesan como neuronas'.

- **Sensor de humedad con memristor (Advanced Materials, 2026)**: plataforma neuromórfica de sensado de humedad basada en memristor Nafion/Ag/ITO. La variación de humedad genera spikes directamente sin ADC intermedio. Primer sensor de humedad con codificación neuronal nativa.
- **Sistema vibrisal artificial para viento/humedad/temperatura (ResearchGate fig3_335438509)**: sensor autoenergizado que codifica viento, humedad y temperatura en trenes de spikes mediante memristor HfO2 y sensor hidrovoltáico. La señal de salida es directamente procesable por una SNN sin conversión analógico-digital.
- **Monitoreo de salud estructural post-terremoto (ResearchGate fig3_344229760)**: factibilidad demostrada de SNN para monitoreo continuo de vibraciones en estructuras, con activación solo cuando se detectan patrones anómalos que sugieren daño estructural.

8.3 Visión y robótica

- **Cámaras de eventos (DVS)**: generan spikes solo cuando cambia el brillo de un pixel, no frames completos. Latencia de microsegundos. Las SNN son el procesador natural para estas cámaras — ANN convencionales no aprovechan su estructura temporal.
- **Robot de tenis de mesa (Ziegler et al., 2024)**: SNN en hardware neuromórfico detecta pelota en movimiento rápido en tiempo real, con latencia y consumo inviables para GPU equivalente en el mismo

task.

8.4 Detección de interferencias de radio (RFI) en radio telescopios

Un caso de uso reciente y representativo del estado del arte: SNN para detección de RFI en el telescopio HERA. La señal de radio es naturalmente esparsa y temporal — exactamente el dominio donde las SNN son superiores. Los resultados muestran 'state-of-the-art detection accuracy' con estimaciones de eficiencia energética que hacen viable el deployment en hardware neuromórfico Xylo en el telescopio.

- **QLIF-CAST (2025):** neurona LIF cuántica para forecasting de series temporales climáticas. El paper usa el LIF clásico como baseline — exactamente lo que tu paper propone como detector. Esto confirma que el LIF es un punto de referencia legítimo y activamente investigado en el contexto climático.

9. El modelo LIF simplificado de tu paper: posición exacta en el campo

Con el panorama completo de las SNN establecido, se puede posicionar con precisión qué hace tu paper y qué no hace.

Dimensión	SNN completa	Tu modelo LIF simplificado
Número de neuronas	Miles a millones	Una sola neurona (single-neuron model)
Aprendizaje	STDP, surrogate gradients, backprop-through-time	Sin aprendizaje — parámetros ajustados manualmente
Codificación	Rate, temporal, population coding	Rate coding implícito: mayor temperatura → mayor corriente → más spikes
Conexiones sinápticas	Matriz de pesos aprendida	Pesos fijos definidos por el diseñador (contribución de cada variable)
Hardware	Loihi, Xylo, TrueNorth	Python / numpy (simulación software)
Dinámica temporal	Múltiples escalas temporales, STDP	Una constante de tiempo τ y un período refractario simple
Marco matemático	EDO acopladas, redes recurrentes, teoría de campos	Una EDO de primer orden, discretizada con Euler
Precedente en literatura	Redes completas para clasificación e imagen	EONS, Vacuum Spiker: neurona de salida única para detección binaria
Nombre correcto en el paper	SNN (no usar)	'Modelo LIF simplificado bio-inspirado' o 'modelo de integración temporal bio-inspirado'

CONCLUSIÓN PARA EL PAPER: tu modelo es un LIF de una sola neurona con parámetros fijos, sin aprendizaje, implementado en Python, usando rate coding implícito. Esto es exactamente lo que EONS y Vacuum Spiker usan como arquitectura mínima para detección binaria en series temporales. La diferencia original de tu trabajo es el dominio de aplicación (variables climáticas argentinas del SMN) y la comparación directa contra un detector de umbral estático como baseline. El framing correcto: 'inspirado en el modelo LIF de primera neurona, proponemos un detector de eventos climáticos extremos que incorpora integración temporal con decaimiento exponencial, ausente en los sistemas de umbral estático actuales'.

10. Referencias

Fundacionales — Modelo LIF y neurona biológica

- Lapique, L. (1907). Recherches quantitatives sur l'excitation électrique des nerfs traitée comme une polarisation. Journal de Physiologie et de Pathologie Générale, 9, 620–635.
- Abbott, L.F. (1999). Lapique's introduction of the integrate-and-fire model neuron (1907). Brain Research Bulletin, 50(5-6), 303–304.
- Brunel, N., & van Rossum, M.C.W. (2007). Lapique's 1907 paper: from frogs to integrate-and-fire. Biological Cybernetics, 97(5-6), 337–339.
- Gerstner, W., Kistler, W.M., Naud, R., & Paninski, L. (2014). Neuronal Dynamics. Cambridge University Press. (Cap. 1.3: Integrate-and-Fire model)

Variabilidad neuronal y modelos estocásticos

- Gerstein, G.L., & Mandelbrot, B. (1964). Random walk models for the spike activity of a single neuron. Biophysical Journal, 4(1), 41–68.
- Stein, R.B. (1965). A theoretical analysis of neuronal variability. Biophysical Journal, 5(2), 173–194.
- Stein, R.B. (1967). Some models of neuronal variability. Biophysical Journal, 7(1), 37–68.
- Plesser, H.E., & Geisel, T. (2001). Signal selection based on stochastic resonance. arXiv:physics/0004019.

Tercera generación y potencia computacional

- Maass, W. (1997). Networks of spiking neurons: the third generation of neural network models. Neural Networks, 10(9), 1659–1671.

Aprendizaje en SNN

- Neftci, E.O., Mostafa, H., & Zenke, F. (2019). Surrogate gradient learning in spiking neural networks. IEEE Signal Processing Magazine, 36(6), 51–63.

Hardware neuromórfico

- Davies, M., et al. (2018). Loihi: A Neuromorphic Manycore Processor with On-Chip Learning. IEEE Micro, 38(1), 82–99.

Aplicaciones en detección de anomalías

- Vázquez, I.X., et al. (2025). Vacuum Spiker: A Spiking Neural Network-Based Model for Efficient Anomaly Detection in Time Series. arXiv:2510.06910.
- EONS — Binary classification in multivariate time series with single output neuron. arXiv:2510.20997.

Sensores neuromórficos ambientales

- Plataforma neuromórfica de sensado de humedad basada en memristor Nafion/Ag/ITO. Advanced Materials, 2026.
- Sistema vibril artificial para codificación de viento, humedad y temperatura. ResearchGate fig3_335438509.
- Factibilidad de SNN para monitoreo de salud estructural post-terremoto. ResearchGate fig3_344229760.

LIF aplicado a clima

- QLIF-CAST: Quantum Leaky-Integrate-and-Fire for Time-Series Weather Forecasting. arXiv:2605.18333 (2025).

LIF como detector de cambios

- The Leaky Integrate-and-Fire Neuron Is a Change-Point Detector for Compound Poisson Processes. Neural Computation, MIT Press (2025).