



U.T.N.
Fac. Reg. Villa María
2022

Probabilidad y Estadística

Síntesis de:


Esperanza Matemática

Carlos R. Colazo

Docentes:

Esp. Ing. Sergio TOVO
Ing. Romina VERDOIA
Prof. Daniela ARIAS





ESPERANZA MATEMÁTICA

La esperanza matemática (también llamado valor esperado) es la suma de los productos de todos los posibles valores de la variable aleatoria por sus respectivas probabilidades. Cuando se trata de una variable aleatoria continua, la suma se transforma en una integral.

$$E(X) = x_1 \cdot P(X = x_1) + \dots + x_n \cdot P(X = x_n) =$$

$$= \sum_{i=1}^n x_i \cdot P(X = x_i) \quad (\text{caso directo})$$

$$\text{como } P(X = x_i) = f(x_i)$$

$$E(X) = x_1 \cdot f(x_1) + x_2 \cdot f(x_2) + \dots = \sum_{i=1}^n x_i \cdot f(x_i).$$

Para el caso especial cuando las probabilidades son iguales, tenemos:

$$E(X) = (x_1 + x_2 + x_3 + \dots + x_n) \cdot \frac{1}{n} = \mu$$

que se llama media aritmética o simplemente media.

Para una variable aleatoria continua X que tiene una función de densidad $f(x)$ la Esperanza de X se define como:

$$E(X) = \int_{-\infty}^{+\infty} x \cdot f(x) \cdot dx \quad (\text{caso continuo})$$

A la esperanza de X frecuentemente se la llama media de X y se la denomina por μ_x , o simplemente μ cuando se sobreentiende la variable aleatoria determinada.


La media o esperanza de X da un valor típico o promedio de los valores de X y por esta razón se le llama medida de centralización.

El nombre de Esperanza Matemática surge de la tradición, asociada con los juegos de azar y representa la ganancia que el jugador puede esperar por cada jugada cuando juega con un número indefinidamente grande de ellas.

Ejemplo casos discretos:

a) Cuál es la esperanza matemática en la tirada de un dado balanceado?. Si la variable aleatoria X asume los siguientes valores 1,2,3,4,5 y 6, donde la probabilidad para cada uno de ellos es igual a $1/6$.

Por lo tanto:



$$E(X) = \sum_{i=1}^6 x_i \cdot P(X = x_i) = 1 \cdot \frac{1}{6} + 2 \cdot \frac{1}{6} + 3 \cdot \frac{1}{6} \dots = \frac{21}{6}$$

Es decir si el juego consiste en ganar \$ 1 por número que salga para que el juego sea correcto debemos pagar $\frac{21}{6} = 3,50$ por tirada.

b) Si se lanzan tres monedas al aire simultáneamente, donde la variable aleatoria X es el número de caras, representada por la siguiente tabla:

x_i	0	1	2	3
$f(x_i)$	1/8	3/8	3/8	1/8

$$E(X) = \sum_{i=1}^4 x_i \cdot P(X = x_i) = 0 \cdot \frac{1}{8} + 1 \cdot \frac{3}{8} + 2 \cdot \frac{3}{8} + 3 \cdot \frac{1}{8} \dots = \frac{18}{8}$$

Es decir si lanzamos una gran cantidad de veces tres monedas balanceadas, obtendremos en promedio 2 caras.

c) Supóngase un juego con un dado. En este juego el jugador gana \$ 20 si obtiene 2, \$ 40 si obtiene 4, pierde \$ 30 si obtiene 6, en tanto que ni pierde ni gana si obtiene otro resultado. Hallar la suma esperada de dinero ganado.

Podemos realizar la siguiente tabla:


x_i	0	20	0	40	0	-30
$f(x_i)$	1/6	1/6	1/6	1/6	1/6	1/6

por lo tanto será:

$$\begin{aligned} E(X) &= 0 \cdot \frac{1}{6} + 20 \cdot \frac{1}{6} + 0 \cdot \frac{1}{6} + 40 \cdot \frac{1}{6} + \\ &\quad + 0 \cdot \frac{1}{6} + (-30) \cdot \frac{1}{6} = \\ &= \frac{0 + 20 + 40 + 0 - 30}{6} = 5 \end{aligned}$$

Se deduce que el jugador puede esperar una ganancia de \$ 5. Por lo tanto en un juego honrado es de esperarse pagar \$ 5 por jugar.

Ejemplo caso continuo: La función de densidad de una variable aleatoria X está dada por:



$$f(x) = \begin{cases} \frac{1}{2} \cdot x & 0 < x < 2 \\ 0 & \text{de otra forma} \end{cases}$$

El valor esperado de X es:

$$E(X) = \int_{-\infty}^{\infty} x \cdot f(x) \cdot dx = \int_0^2 x \cdot \frac{1}{2} x \cdot dx = \left[\frac{x^3}{6} \right]_0^2 = \frac{4}{3}$$

Propiedades de la esperanza

a) Si $Q(x)$ es una función de x y si x es una variable aleatoria discreta entonces:

$$E[Q(X)] = \sum_{i=1}^n Q(x_i) \cdot f(x_i) \quad \text{caso directo}$$

$$E[Q(X)] = \int_{-\infty}^{\infty} Q(x) \cdot f(x) \cdot dx \quad \text{caso continuo}$$

b) Si k es una constante y X una variable aleatoria con $E(X)$, entonces:

$$E(k) = k$$


$$E(K \cdot X) = \sum_{i=1}^n k \cdot x_i \cdot f(x_i) = k \sum_{i=1}^n x_i \cdot f(x_i) = k \cdot E(X)$$

$$E(X + K) = \sum_{i=1}^n (x_i + k) \cdot f(x_i) = \sum_{i=1}^n x_i \cdot f(x_i) + \sum_{i=1}^n k \cdot f(x_i) = E(X) + k$$

c) La esperanza matemática de una suma finita de variables aleatorias es igual a la suma de sus esperanzas:

$$\begin{aligned} E(X + Y) &= \sum_{i=1}^n (x_i + y_i) \cdot H(x_i, y_i) = \sum_{i=1}^n x_i \cdot H(x_i, y_i) + \sum_{i=1}^n y_i \cdot H(x_i, y_i) \\ &= \sum_{i=1}^n x_i \cdot f(x_i) + \sum_{i=1}^n y_i \cdot h(y_i) = E(X) + E(Y) \end{aligned}$$

Este teorema se cumple si las variables aleatorias son independientes o no lo son.



d) Si X e Y son variables aleatorias independientes con esperanzas $E(X)$ y $E(Y)$ respectivamente entonces:


$$\begin{aligned} E(X \cdot Y) &= \sum_{i=1}^n x_i \cdot y_i \cdot h(x_i, y_i) = \sum_{i=1}^n x_i \cdot y_i f(x_i) \cdot g(y_i) \\ &= \sum_{i=1}^n x_i \cdot f(x_i) \cdot \sum_{i=1}^n y_i \cdot g(y_i) = E(X) \cdot E(Y) \end{aligned}$$


Esta propiedad puede ser extendida al producto de un número finito de variables aleatorias independientes.

Varianza y Desviación Típica

La Esperanza Matemática corresponde a un parámetro que nos describe la tendencia central de una variable aleatoria. Sin embargo puede suceder que aún en el caso de aparecer dos distribuciones con idénticas esperanzas, las mismas pueden ser totalmente distintas debido a la dispersión o variabilidad de los valores de la variable aleatoria. Es decir que además de la *Esperanza Matemática* que nos proporciona la información sobre el valor más probable del experimento donde las pruebas se repiten un número grande de veces, para contar con la descripción completa de la distribución de probabilidad, es necesario conocer la concentración de los resultados de dichas pruebas, alrededor de dicha esperanza.

Consideramos únicamente la *Varianza* y el *Error Estándar* o *desviación típica* (también llamada desviación estándar) como medida de variabilidad, ya que son las más usadas como medida de dispersión. Si los valores tienden a concentrarse alrededor de la media, la varianza es pequeña; en tanto que si los valores tienden a distribuirse lejos de la media, la varianza es grande.





Como muestra la figura para el caso de dos distribuciones continuas con la misma μ . Dada una variable aleatoria X representaremos su varianza por $\text{Var}(X)$, o si se define por:

$$\text{Var}(X) = \sum_{i=1}^n [x_i - E(X)]^2 \cdot f(x_i) \quad \text{caso directo}$$

$$\text{Var}(X) = \int_{-\infty}^{\infty} [x_i - E(X)]^2 \cdot f(x) \cdot dx \quad \text{caso continuo}$$

Lo que es igual a:

$$\text{Var}(X) = E[(X - \mu)^2] = \sum_{i=1}^n (x_i - \mu)^2 \cdot f(x_i) = \sigma^2$$

donde X es una variable aleatoria discreta y con función de probabilidad $f(x)$. Y también:

$$\text{Var}(X) = E[(X - \mu)^2] = \int_{-\infty}^{\infty} (x - \mu)^2 \cdot f(x) \cdot dx = \sigma^2$$

donde X es una variable aleatoria continua.

Definimos como Desviación Típica o Error Estándar o Desviación Estándar a la raíz cuadrada de la varianza:

$$\sigma = \sqrt{\sigma^2} = \sqrt{\text{Var}(X)} = \sqrt{E(X - \mu)^2}$$

EJEMPLOS

a) En los ejercicios anteriores podemos obtener para el caso a- $\sigma=1,71$; para el b- $\sigma=1,15$; y c- $\sigma=21,41$.


b) La función de densidad de una variable aleatoria X está dada por:

$$f(x) = \begin{cases} -2x & x \geq 0 \\ 2 \cdot e & x < 0 \\ 0 & \end{cases}$$

si calculamos primero la media:

$$\mu = \int_0^{\infty} x \cdot 2 \cdot e^{-2x} \cdot dx = \left[-x \cdot e^{-2x} - \frac{1}{2} \cdot e^{-2x} \right]_0^{\infty} = \frac{1}{2}$$

por lo tanto la varianza será:



$$\begin{aligned}\text{Var}(X) &= E\left(X - \mu\right)^2 = \int_0^{\infty} \left(x - \frac{1}{2}\right)^2 \cdot e^{-2x} \cdot dx = \\ &= \int_0^{\infty} \left(x^2 \cdot e^{-2x} + \frac{1}{4} \cdot dx \cdot e^{-2x}\right) \cdot dx = \frac{1}{4}\end{aligned}$$

y la desviación típica está dada por:

$$\sigma = \sqrt{\text{Var}(X)} = \frac{1}{2}$$

Propiedades de la Varianza

a) Siendo X una variable aleatoria y la media $\mu = E(X)$, tenemos:

$$\begin{aligned}\text{Var}(X) &= E\left[(X - \mu)^2\right] = E(X^2 - 2\mu X + \mu^2) = E(X^2) - 2\mu E(X) + \mu^2 = \\ &= E(X^2) - 2\mu^2 + \mu^2 = E(X^2) - [E(X)]^2 \\ &= E(X^2) - \mu^2\end{aligned}$$

b) Si k es un número real y X una variable aleatoria con varianza $\text{Var}(X)$ entonces:

$$\text{Var}(k) = E(K - E(K))^2 = E(k - k)^2 = E(0) = 0$$

y también:

$$\begin{aligned}\text{Var}(X + K) &= E\left\{\left[(X + k) - E(X + k)\right]^2\right\} = E\left[(X + k)^2 - 2 \cdot (X + k) + (\mu + k)^2\right] = \\ &= E(X^2) + E(2kX) + E(k^2) - E(2\mu X) - E(2kX) - E(2k^2) - E(2\mu k) + \mu^2 + 2\mu k + k^2 = \\ &= E(X^2) + k^2 - 2\mu^2 - 2k^2 - 2\mu k + \mu^2 + 2\mu k + k^2 = \\ &= E(X^2) - \mu^2 = \\ &= \text{Var}(X)\end{aligned}$$

$$\begin{aligned}\text{Var}(k \cdot X) &= E\left\{\left[(k \cdot X) - E(k \cdot X)\right]^2\right\} = \left[k^2 X^2 - 2k^2 \mu X + K^2 \mu^2\right] = \\ &= k^2 \cdot E\left[X^2 - 2\mu X + \mu^2\right] = \\ &= k^2 \cdot E\left[(X - \mu)^2\right] = \\ &= k^2 \cdot \text{Var}(X)\end{aligned}$$

c) Si X e Y son dos variables aleatorias, entonces:



$$\begin{aligned}\text{Var}(X + Y) &= E\left[\left\{(X + Y) - (\mu_x + \mu_y)\right\}^2\right] = E\left[\left\{(X - \mu_x) + (Y - \mu_y)\right\}^2\right] = \\ &= E\left[(X - \mu_x)^2 + 2 \cdot (X - \mu_x) \cdot (Y - \mu_y) + (Y - \mu_y)^2\right] = \\ &= E[(X - \mu_x)^2] + E[(Y - \mu_y)^2] = \\ &= \text{Var}(X) + \text{Var}(Y)\end{aligned}$$

Esto es teniendo en cuenta que $E[(X - \mu_x) \cdot (Y - \mu_y)] = 0$ ya que X e Y son independientes. También se puede ver que:

$$\text{Var}(X - Y) = \text{Var}(X) + \text{Var}(Y).$$

y en el caso del producto de dicha variables:

$$\text{Var}(X \cdot Y) = \text{Var}(X) \cdot \text{Var}(Y).$$

Esta propiedad se generaliza para un número infinito de variables aleatorias independientes.

Variables Aleatorias Normalizadas

Es posible estandarizar cualquier variable aleatoria, restando de la misma su esperanza y dividiendo el resultado por su desviación típica, es decir, si X es una variable aleatoria con medida μ_x y desviación típica σ_x , entonces la correspondiente variable estandarizada o normalizada será:


$$Z = \frac{X - \mu_x}{\sigma_x} = \frac{X - E(X)}{\sqrt{\text{Var}(X)}}$$

Si calculamos la Esperanza Matemática tenemos:

$$E(Z) = E\left[\frac{X - E(X)}{\sigma_x}\right] = \frac{1}{\sigma_x} \cdot E[X - E(X)] = \frac{1}{\sigma_x} \cdot [E(X) - E(X)] = 0$$

y si calculamos la varianza de la variable Z, será:

$$\begin{aligned}\text{Var}(Z) &= \text{Var}\left[\frac{X - E(X)}{\sigma_x}\right] = \frac{1}{\sigma_x^2} \cdot \text{Var}[X - E(X)] = \frac{1}{\sigma_x^2} \cdot E\left\{(X - \mu_x)^2\right\} \\ &= \frac{1}{\sigma_x^2} \cdot \sigma_x^2 = 1\end{aligned}$$



Por lo tanto podemos decir que las variables aleatorias estandarizadas o normalizadas tienen siempre esperanza matemática 0 y varianza 1.

La transformación Z tiene como efecto cambiar la escala de la variable original, así como el origen de las mismas.

Los valores de una variable normalizada se denominan algunas veces referencias Tipificadas y X se dice que está expresada en unidades tipificadas. Las variables normalizadas son útiles para comparar diferentes distribuciones.

Momentos

Momento r de una variable aleatoria X alrededor de la media μ , también conocido como Momento Central r, se define como:

$$\mu_r = E[(X - \mu)^r]$$

donde $r = 0, 1, 2, 3, \dots$. Se deduce que:

$$\mu_0 = E(X - \mu)^0 = 1$$

$$\mu_1 = E(X - \mu)^1 = E(X) - \mu = E(X) - E(X) = 0$$

$$\mu_2 = E(X - \mu)^2 = E(X^2) - \mu^2 = \text{Var}(X)$$

Y en forma general tenemos:

$$\mu_r = \sum_{i=1}^n (x_i - \mu)^r \cdot f(x_i) \quad (\text{variable discreta})$$

$$\mu_r = \int_{-\infty}^{\infty} (x - \mu)^r \cdot f(x) \quad (\text{variable continua})$$


El momento r de una variable aleatoria X alrededor del origen, se define como:

$$\mu'_r = E(X^r) \quad \text{donde } r = 1, 2, 3, \dots$$

$$\mu'_0 = E(X^0) = E(1) = 1$$

$$\mu'_1 = E(X^1) = E(X) = \mu$$

y en forma general tenemos:



$$\mu'_r = \sum_{i=1}^n x_i^r \cdot f(x_i) \quad (\text{variable discreta})$$

$$\mu'_r = \int_{-\infty}^{\infty} x^r \cdot f(x) \cdot dx \quad (\text{variable continua})$$

Relación entre momentos

La relación entre el momento con respecto a la media y el momento con respecto al origen se expresa por: (desarrollando el binomio).

$$\mu_r = \mu'_r + \binom{r}{1} \cdot \mu'_{r-1} \mu + \binom{r}{2} \cdot \mu'_{r-2} \mu^2 + \binom{r}{3} \cdot \mu'_{r-3} \mu^3 + \dots + (-1)^j \cdot \binom{r}{j} \mu'_{r-j} \mu^j + \dots + (-1)^r \cdot \mu^r$$

Analizaremos los primeros cinco momentos:

$$\mu_0 = 1$$

$$\mu_1 = 0$$

$$\mu_2 = \mu'_2 - \mu^2$$

$$\mu_3 = \mu'_3 - 3 \mu'_2 \mu + 2 \mu^3$$

$$\mu_4 = \mu'_4 - 4 \mu'_3 \mu + 6 \mu'_2 \mu^2 - 3 \mu^4$$

Función Generatriz de Momentos

La función generatriz de momentos se define por:

$$M_X(t) = E(e^{tx})$$


Para variables discretas:

$$M_X(t) = \sum [e^{tx} \cdot f(x)]$$

Para variables continuas:

$$M_X(t) = \int_{-\infty}^{\infty} e^{tx} \cdot f(x) dx.$$

Si aplicamos el desarrollo en serie de MacLaurin para la función e^{tx} , tenemos:



$$M_x(t) = E(e^{tx}) = E(1 + t \cdot x + t^2 \cdot x^2/2! + t^3 \cdot x^3/3! + t^4 \cdot x^4/4! + \dots)$$

$$= 1 + t \cdot E(X) + t^2/2! \cdot E(X^2) + t^3/3! \cdot E(X^3) + \dots + t^n/n! \cdot E(X^n)$$

$$= 1 + \mu_1 t + \mu_2' \cdot t^2/2! + \mu_3' \cdot t^3/3! + \dots + \mu_n' \cdot t^n/n!$$

es decir que la siguiente función nos permite calcular la función generatriz de momentos:

$$\mu_r' = \left. \frac{d \cdot M_x(t)}{dt^r} \right|_{t=0}$$

EJEMPLO

Calcular los primeros cinco momentos alrededor de la media y del origen para una variable aleatoria X con función de densidad:

$$f(x) = \begin{cases} 4x \frac{(9-x^2)}{81} & 0 \leq x \leq 3 \\ 0 & \text{de otra forma} \end{cases}$$

Los momentos respecto del origen serán:

$$\mu_1' = E(X) = \frac{4}{81} \int_0^3 x^2 (9 - x^2) \cdot dx = \frac{8}{5} = \mu$$


$$\mu_2' = E(X^2) = \frac{4}{81} \int_0^3 x^3 (9 - x^2) \cdot dx = 3$$

$$\mu_3' = E(X^3) = \frac{4}{81} \int_0^3 x^4 (9 - x^2) \cdot dx = \frac{216}{35}$$

$$\mu_4' = E(X^4) = \frac{4}{81} \int_0^3 x^5 (9 - x^2) \cdot dx = \frac{27}{2}$$

Los momentos respecto de la media serán:

$$\mu_1 = 0$$



$$\mu_2 = 3 - \left(\frac{8}{5}\right)^2 = \frac{11}{25} = \sigma^2$$

$$\mu_3 = \frac{216}{35} - 3 \cdot (3) \cdot \left(\frac{8}{5}\right) + 2 \cdot \left(\frac{8}{5}\right) = -\frac{32}{875}$$

$$\mu_4 = \frac{27}{2} - 4 \cdot \left(\frac{216}{35}\right) \cdot \left(\frac{8}{5}\right) + 6 \cdot (3) \cdot \left(\frac{8}{5}\right)^2 - 3 \cdot \left(\frac{8}{5}\right)^4 = \frac{693}{8750}$$

Otras Medidas de Centralización


Como hemos visto, la media o esperanza de una variable aleatoria X , provee una medida de centralización son la Moda y la Mediana, aunque la más usada es la media.


Moda: Es el valor que con mayor frecuencia ocurre, o sea que tiene mayor probabilidad de ocurrir. Es el punto donde la curva $f(x)$, (función densidad) es máxima. Puede ocurrir que tenga varios que tiene relativamente probabilidades de ocurrencia, en estos casos se llama multimodal.

Mediana: La mediana es el valor de x para el cual $P(X \leq x) = P(X \geq x) = \frac{1}{2}$.

En el caso de distribución continua la mediana corresponde a la ordenada que separa una curva de densidad en dos partes que tienen áreas iguales de $\frac{1}{2}$ cada una. En caso de distribución discreta puede no existir una mediana única.

Percentilla: Con frecuencia es conveniente subdividir el área bajo una curva de densidad empleando ordenadas de manera que el área a la izquierda de la ordenada sea algún porcentaje del área total. Los valores que corresponden a tales áreas se llaman valores percentilla. Así por ejemplo el área a la izquierda de la ordenada en x_α en la figura es α . Por ejemplo el área a la izquierda de $x_{.10}$ sería 0.10 o 10% y se llamaría la décima percentilla (o la primera decila o primera décima). La mediana sería la quincuagésima percentilla (o la quinta décima).





Otras medidas de dispersión

Así como hay varias medidas de centralización además de la media, hay diferentes medidas de dispersión o variación respecto de estas medidas centrales además de la varianza o desviación típica. Algunas son:

Recorrido: El pequeño recorrido es la diferencia entre los valores más grande y más pequeño de una distribución. Lógicamente, esta medida no tiene sentido si algunos de los valores extremos es infinito.

Recorrido semi-intercuartílico: Si x_{25} y x_{75} representan los valores de la vigésima quinta y la setuagésima quinta percentilla la diferencia $x_{75} - x_{25}$ se la llama el recorrido intercuartílico y por lo tanto la mitad de dicha diferencia se le llama recorrido semi-intercuartílico.

Desviación media: La desviación media D.M de una variable aleatoria x se define como la esperanza de $|X - \mu|$, es decir:

$$D \cdot M \cdot (X) = E[|X - \mu|] = \sum_{i=1}^n |x_i - \mu| \cdot f(x_i) \quad (\text{variables discretas})$$



$$D \cdot M \cdot (X) = E[|X - \mu|] = \int_{-\infty}^{\infty} |x_i - \mu| f(x) \cdot dx \quad (\text{variables continuas})$$

Coefficiente de Sesgo y Curtosis

Sesgo: Con frecuencia una distribución no es simétrica con respecto a un máximo sino que tiene una "cola" más larga que la otra. Si la cola más larga se extiende a la derecha, se dice que la distribución está sesgada a la derecha, mientras que si la cola más larga se extiende a la izquierda, se dice que está sesgada a la izquierda. Las medidas que describen esta simetría se denominan coeficiente de sesgo o simplemente sesgo. que se obtiene por:

$$\alpha_3 = \frac{E[(X - \mu)^3]}{\sigma^3} = \frac{\mu^3}{\sigma^3}$$

que es una cantidad adimensional. Si es positiva la distribución está sesgada a la derecha, si es negativa la distribución está sesgada a la izquierda. Para una distribución simétrica $\alpha_3 = 0$





Curtosis: En algunos casos una distribución puede tener sus valores concentrados cerca de la media así que la distribución tiene un pico grande como se indica por la curva sólida en la figura. En otros casos la distribución puede ser relativamente plana como en el caso de la curva de trazos. La medida del grado de aplastamiento de una distribución se llama coeficiente de curtosis o simplemente curtosis.

Este se obtiene por:

$$\alpha_4 = \frac{E[(X - \mu)^4]}{\sigma^4} = \frac{\mu^4}{\sigma^4}$$

que es una cantidad adimensional. Comúnmente se comparan con la curva normal que tiene $\alpha_4 = 3$





Ejemplo: Dada la función de densidad de una variable aleatoria continua X, por

$$f(x) = \begin{cases} \frac{4x(9-x^2)}{81} & 0 \leq x \leq 3 \\ 0 & \text{de otra forma} \end{cases}$$

La **media** es:

$$E(X) = \frac{4}{81} \int_0^3 x^2 \cdot (9-x^2) \cdot dx = \left[\frac{4}{81} \cdot \left(3 \cdot x^3 - \frac{x^5}{5} \right) \right]_0^3 = 1,60$$

La **moda** es:

$$\frac{d}{dx} [4x \cdot (9-x^2)] = 36 - \frac{12x^2}{81} = 0$$

$$\text{por lo tanto } x = \sqrt{3} = 1,7321$$

La **mediana** es:

$$P(X \leq a) = \frac{4}{81} \cdot \int_0^3 x \cdot (9-x^2) \cdot dx = \frac{4}{81} \cdot \left(9 \cdot \frac{a^2}{2} - \frac{a^4}{4} \right) = \frac{1}{2}$$

donde despejamos se tiene:

$$2a^4 - 36a^2 + 81 = 0 \quad \therefore \quad a^2 = 9 \pm \frac{\sqrt{648}}{4} = 9 \pm \frac{9}{2}\sqrt{2}$$


como la mediana pedida debe hallarse entre 0 y 3 por lo tanto el valor

$$a^2 = 9 \pm \frac{\sqrt{648}}{4} \quad \text{o sea } a = 1,6236$$

La décima percentilla o primer decila es:

$$P(X \leq a) = \frac{4}{81} \left(\frac{9a^2}{2} - \frac{a^4}{4} \right) = \frac{(18a^2 - a^4)}{81} = 0,10$$

$$a = 0,6796 = x_{10}$$



La vigésima quinta percentilla es:

$$P(X \leq a) = \frac{4}{81} \cdot \left(\frac{9a^2}{2} - \frac{a^4}{4} \right) = \frac{(18a^2 - a^4)}{81} = 0,25$$

$$a = 1,0981 = x_{25}$$

La septuagésima quinta percentilla es:

$$P(X \leq a) = \frac{4}{81} \left(\frac{9a^2}{2} - \frac{a^4}{4} \right) = \frac{(18a^2 - a^4)}{81} = 0,75$$

$$a = 2,1213 = x_{75}$$

El recorrido es: Valor máximo = 3, Valor mínimo = 0

$$\text{recorrido} = 3 - 0 = 3$$

El recorrido semi-intercuartílico es:

$$R.S.I. = (x_{.75} - x_{.25}) / 2 = (2,1213 - 1,0981) / 2 = 0,5116$$

La desviación media es:

$$\begin{aligned} D \cdot M &= \int_0^3 |x - 1,6| \cdot \frac{4x}{81} \cdot (9 - x^2) \cdot dx = \\ &= \int_0^{1,6} (1,6 - x) \cdot \frac{4x}{81} \cdot (9 - x^2) \cdot dx - \int_{1,6}^3 (x - 1,6) \cdot \frac{4x}{81} \cdot (9 - x^2) dx = \\ &= 0,555 \end{aligned}$$

La **Varianza** es:

$$\text{Var}(X) = \int_0^3 (x - 1,6)^2 \cdot \frac{4x}{81} \cdot (9 - x^2) dx = \frac{11}{25} = 0,44$$

La desviación típica es:

$$\sigma = \sqrt{0,44} = 0,6633$$




El coeficiente de sesgo es:

$$\sigma_3 = \frac{\mu_3}{\sigma^3} = -\frac{0,0366}{0,2918} = -0,1254$$

El coeficiente de curtosis es:

$$\sigma_4 = \frac{\mu_4}{\sigma^4} = \frac{0,4221}{0,1936} = 2,1805$$

Representación gráfica:



Desigualdad de Chebyshev

Un teorema importante en probabilidad y estadística que revela una propiedad de las variables aleatorias discretas o continuas con media y varianza finita se conoce como desigualdad de Chebyshev.


Teniendo en cuenta que:

$$\sigma^2 = E[(X - \mu)^2] = \int_{-\infty}^{\infty} (x - \mu)^2 \cdot f(x) \cdot dx$$

El valor de la integral disminuye cuando el intervalo de integración disminuye. Por lo tanto:

$$\sigma^2 \geq \int_{|x-\mu| \geq k\sigma} (x - \mu)^2 \cdot f(x) \cdot dx$$

Teniendo en cuenta que para $x \geq \mu + k\sigma \Rightarrow x - \mu \geq k\sigma$, y para $x \leq \mu - k\sigma \Rightarrow x - \mu \leq -k\sigma$ por lo tanto podemos decir $|x - \mu| \geq k\sigma$ de donde $(x - \mu)^2 \geq k^2\sigma^2$.



$$\sigma^2 \geq \int_{|x-\mu| \geq k\sigma} k^2 \sigma^2 \cdot f(x) \cdot dx = k^2 \sigma^2 \cdot \int_{|x-\mu| \geq k\sigma} f(x) \cdot dx$$

donde tenemos el teorema de Chebyshev:

$$\frac{1}{k^2} \geq \int_{|x-\mu| \geq k\sigma} f(x) \cdot dx \quad \Rightarrow \quad P(|X - \mu| \geq k\sigma) \leq \frac{1}{k^2}$$

Si $k=2$ en la desigualdad de Chebyshev, vemos que:

$$P(|X - \mu| \geq 2\sigma) \leq 0,25 \quad \text{o} \quad P(|X - \mu| < 2\sigma) \geq 0,75$$

La probabilidad de que X difiera de su media en más de dos desviaciones típicas es menor ó igual as 0,25; equivalente, la probabilidad de que X se encuentre dentro de dos desviaciones típicas de su media es mayor que o igual. Esto es bastante extraordinario si se tiene en cuenta que aún no se ha especificado la distribución de probabilidad de X .

EJEMPLO. Para la variable aleatoria X que tiene como función de densidad:



$$f(x) = \begin{cases} 2 \cdot e^{-2x} & x \geq 0 \\ 0 & x \leq 0 \end{cases}$$

Hallar la $P(|X - \mu| > 1)$ y utilizar la desigualdad de Chebyshev para obtener un límite superior de $P(|X - \mu| > 1)$ y comprobar los resultados.

$$\mu = E(X) = \int_0^{\infty} 2x \cdot e^{-2x} \cdot dx = \left[-xe^{-2x} - \frac{e^{-2x}}{4} \right]_0^{\infty} = \frac{1}{2} = 0,5$$

$$P(|X - \mu| < 1) = P(|X - 0,5| < 1) = P(-0,5 < x < 1,5) = \int_0^{1,5} 2 \cdot e^{-2x} \cdot dx =$$

$$= \left[\frac{2 \cdot e^{-2x}}{-2} \right]_0^{1,5} = -e^{-3} + 1 = 0,9502$$



$$P(|X - 0,5| \geq 1) = 1 - (1 - e^{-3}) = 0,0498$$

La varianza es:

$$\sigma^2 = \text{Var}(X) = E(X^2) - \mu^2 = \int_0^{\infty} 2x^2 \cdot e^{-2x} dx - (0,5)^2 = 0,25$$

por la desigualdad de Chebyshev: siendo $\varepsilon = k\sigma$

$$P(|X - 0,5| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2} \therefore P(|X - 0,5| \geq 1) \leq 0,25$$

Podemos observar que el límite dado por la desigualdad es bastante crudo. En la práctica se emplea para dar estimativos cuando es imposible obtener valores exactos.

EJEMPLO. Se determinó que el número de clientes que visitan la sala de exhibición de una empresa automotriz un sábado por la mañana es una variable aleatoria con $\mu = 18$ y $\sigma = 2,5$ ¿con qué probabilidad podemos asegurar que habrá entre 8 y 28 clientes?.


En vista de que $K = \frac{28-18}{2,5} = 4$, la probabilidad es al menos $1 - \frac{1}{4^2} = \frac{15}{16} = 0,9375$.

La característica más importante del teorema de Chebyshev es que se aplica a cualquier distribución para la cual existan μ y σ , con la desventaja que solo nos proporciona una cota superior o inferior como se quiera ver.

Ley de los Grandes Números

Sean $X_1, X_2, \dots, X_n$ variables aleatorias mutuamente independientes (discretas o continuas), cada una con media μ y varianza σ^2 finitas.

Entonces si: $s_n = X_1 + X_2 + X_3 + \dots + X_n$



Tenemos que:

$$E(X_1) = E(X_2) = \dots = E(X_n) = \mu \text{ y } \text{Var}(X_1) = \text{Var}(X_2) = \dots = \text{Var}(X_n) = \sigma^2$$

Entonces:

$$E\left(\frac{S_n}{n}\right) = E\left(\frac{X_1 + X_2 + \dots + X_n}{n}\right) = \left(\frac{1}{n}\right) \cdot \{E(X_1) + \dots + E(X_n)\} = \frac{1}{n}(n\mu) = \mu$$

y también:

$$\text{Var}(S_n) = \text{Var}(X_1 + \dots + X_n) = \text{Var}(X_1) + \dots + \text{Var}(X_n) = n \cdot \sigma^2$$

y por lo tanto

$$\text{Var}\left(\frac{S_n}{n}\right) = \frac{1}{n^2} \cdot \text{Var}(S_n) = \left(\frac{1}{n^2}\right) \cdot n \cdot \sigma^2 = \frac{\sigma^2}{n}$$

Si tenemos en cuenta la desigualdad de Chebyshev con $X = \frac{S_n}{n}$, tenemos:

$$P\left(\left|\frac{S_n}{n} - \mu\right| \geq \varepsilon\right) \leq \frac{\sigma^2}{n\varepsilon^2}$$

Tomando límite para $n \rightarrow \infty$ en ambos lados de la desigualdad, tenemos:

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{S_n}{n} - \mu\right| \geq \varepsilon\right) \leq \lim_{n \rightarrow \infty} \frac{\sigma^2}{n\varepsilon^2} = 0$$


Puesto que $\frac{S_n}{n}$ es la media aritmética de $X_1, X_2, \dots, X_n$, esta desigualdad establece la probabilidad de que la media aritmética $\frac{S_n}{n}$ difiera de su valor esperado μ por más de ε , tiende a 0 cuando $n \rightarrow \infty$. Un resultado más fuerte, que esperamos sea verdadero es que:

$$\lim_{n \rightarrow \infty} \frac{S_n}{n} = \mu$$

pero, realmente es falso. Sin embargo podemos demostrar que

$$\lim_{n \rightarrow \infty} \frac{S_n}{n} = \mu$$

con probabilidad 1. Con frecuencia este resultado se denomina ley de los grandes números en forma fuerte y, en contraste, el resultado de la ecuación (1) se llama ley de los grandes



números en forma débil. Cuando se hace referencia a la "ley de los grandes números", se implica la ley débil.

En forma general podemos decir que si se aumenta el número de veces que se repite un experimento, la razón del número de ocurrencias exitosas con respecto al número de ensayos tenderá a aproximarse a la probabilidad teórica del resultado de un ensayo individual.

Ejemplo: Generamos un simulador, con el programa Pascal presentado a continuación, que nos representa el lanzamiento de un dado honrado y en el cuadro siguiente representamos la probabilidad obtenida para 100, 1000, 10.000, 100.000 y 1.000.000 de lanzamientos:

Programa en Pascal:

```
PROGRAM PROG5;
USES
  crt;
VAR
  x: integer;
  l, I: longint;
  c1, c2, c3, c4, c5, c6 : longint;
  c : char;
BEGIN
  c1:=0, c2:=0, c3:=0, c4:=0, c5:=0, c6:=0;
  clrscr;
  writeln ('Ingrese la cantidad de lanzamientos?');
  read (1);
  for I:=1 to 1 do
    begin
      x:Random(6)+1
      if x=1 then c1:=c1+1;
      if x=2 then c1:=c1+1;
      if x=3 then c1:=c1+1;
      if x=4 then c1:=c1+1;
      if x=5 then c1:=c1+1;
      if x=6 then c1:=c1+1;
    end;
  writeln ('c1=',c1) ; writeln ('c2=',c2) ; writeln ('c3=',c3) ; writeln ('c4=',c4) ;
  writeln ('c5=',c5) ; writeln ('c6=',c6) ;
  gotoXY (32,24) ;
  write ('Presione una tecla');
  c:=readkey
END
```



Resultados obtenidos luego de la simulación para cada uno de los casos:

	100		1.000		10.000		100.000		1.000.000	
Nro.	Cant.	Prob.	Cant.	Prob.	Cant.	Prob.	Cant.	Prob.	Cant.	Prob.
1	15	0,15	151	0,151	1.641	0,1641	16.849	0,16849	167.084	0,16708
2	18	0,18	167	0,167	1.649	0,1649	16.772	0,16722	166.689	0,16669
3	21	0,21	184	0,184	1.697	0,1697	16.891	0,16891	166.328	0,166633
4	17	0,27	160	0,160	1.716	0,1716	16.578	0,16578	166.875	0,16687
5	18	0,18	179	0,179	1.620	0,1620	16.390	0,16390	116.634	0,16663
6	11	0,11	159	0,159	1677	0,1677	16520	0,16520	166.390	0,16639
	100	1	1.000	1	10.000	1	100.000	1	1.000.000	1

Como ya conocemos la **probabilidad teórica** es igual a:

$$P(A) = \frac{1}{6} = 0,166666$$

En el cuadro podemos observar como varia la probabilidad de acuerdo a la variación de N para 100, 1.000, 10.000, 100.000 y 1.000.000, llegando a la conclusión que:

Si se aumenta el número de veces que se repite el experimento (N). la razón del número de ocurrencias exitosas con respecto al número de ensayos tenderá a aproximarse a la probabilidad teórica del resultado de un ensayo individual.