

Contenido PARCIAL TEORICO 3

UNIDAD N°3: DISTRIBUCIONES DE PROBABILIDAD (Parte 2)	30
FICHA N°20 – Teorema del Limite Central	30
FICHA N°21 – Distribución Hipergeométrica	30
FICHA N°22 – Distribución Chi Cuadrado	31
UNIDAD N°4: Estadística	35
FICHA N°23 – Estadística, etapas de la investigación científica	35
FICHA N°24 – Distribución de frecuencias discretas y continuas	40
FICHA N°25 – Representaciones graficas de las distintas variables	42
25.1 Gráficos Lineales	42
25.2 Gráficos de Superficie	43
FICHA N°26 – Ojivas y gráficos especiales	46
RESUMEN DE GRAFICOS	48
FICHA N°27 – Medidas de dispersión o concentración	49
FICHA N°29 – Como calcular la Media, mediana y moda	49
FICHA N°28 – Medidas de asimetría y agudeza	49
UNIDAD N°5: Regresión y Correlación	49
FICHA N°33 – Curvas de ajuste. Regresión	49
FICHA N°34 – Método de los mínimos cuadrados. Recta de mínimos cuadrados	49
FICHA N°35 – Parábola de mínimos cuadrados	49
FICHA N°36 – Regresión múltiple. Coeficiente de correlación lineal y generalizado	49

UNIDAD N°3: DISTRIBUCIONES DE PROBABILIDAD (Parte 2)

FICHA N°20 – Teorema del Limite Central

Como podemos ver existe una semejanza entre las ecuaciones límites de la relación entre las distribuciones binomial y normal con la relación entre las distribuciones de Poisson y normal.

Si tenemos las variables aleatorias $X_1, X_2, X_3, \dots, X_n$ son independientes y tienen media μ y varianza σ^2 , podemos decir que:

$$S_n = X_1 + X_2 + X_3 + \dots + X_n$$

por lo tanto, la esperanza es:

$$E(S_n) = n \cdot \mu$$

por ser independientes y la varianza será:

$$E(S_n) = n \cdot \sigma^2$$

Donde deducimos que la variable aleatoria tipificada será:

$$S_n^* = \frac{S_n - \mu}{\sigma \cdot \sqrt{n}}$$

La función Generatriz de momentos para S_n^* es (aplicando un desarrollo de TAYLOR):

$$E(e^{t \cdot S_n^*}) = \left(1 + \frac{t^2}{2n} + \dots\right)^n \quad \quad E(e^{t \cdot S_n^*}) = e^{t^2/2}$$

nos indica que $\lim_{n \rightarrow \infty}$

O sea que es igual a la función generatriz de momentos de la función Normal Tipificada, si tenemos en cuenta que, por el teorema de la unicidad, que dice que dos variables aleatorias X e Y que tienen funciones generatrices de momentos $M_X(t)$ y $M_Y(t)$ respectivamente, tienen la misma distribución de probabilidades si $M_X(t)$ y $M_Y(t)$ son idénticas o sea **$M_X(t) = M_Y(t)$** .

Por lo tanto el Teorema del Límite Central **revela que una gran clase de distribuciones tienen esta propiedad, también se cumple cuando $X_1, X_2, X_3, \dots$ son variables aleatorias independientes, con la misma media y la misma varianza pero no necesariamente distribuidas idénticamente.**

FICHA N°21 – Distribución Hipergeométrica.

Consideremos un caso particular donde tenemos un depósito con componentes de determinado producto, que contiene **b** componentes en buen estado, pero **m** en mal estado. Si efectuamos **n** pruebas a modo de experimento en el cual se escoge un componente, se observa su estado y se lo introduce nuevamente en el depósito. Este tipo de experimento se conoce como **muestreo con reemplazamiento**. Si denotamos por X la variable aleatoria para el número de componentes en **buen estado** sobre n pruebas, entonces empleando la distribución binomial veremos que la probabilidad de x éxitos es:

$$F(x) = P(X = x) = C_n^x \cdot p^x \cdot q^{n-x} = \frac{n!}{x!(n-x)!} \cdot p^x \cdot q^{n-x}$$

si tenemos en cuenta que: $p = \frac{b}{b+m}$ y $q = \frac{m}{b+m}$, entonces:

$$\begin{aligned} P(X = x) &= \frac{n!}{x!(n-x)!} \cdot \frac{b^x}{(b+m)^x} \cdot \frac{m^{n-x}}{(b+m)^{n-x}} \\ &= \frac{n!}{x!(n-x)!} \cdot \frac{b^x \cdot m^{n-x}}{(b+m)^n} \end{aligned}$$

$$F(x) = P(X = x) = \frac{C_b^x \cdot C_m^{n-x}}{C_{b+m}^n}$$

Si modificamos el experimento anterior de tal forma que el **muestreo sea sin reemplazamiento**, es decir que los componentes no se regresen a la caja luego de ser seleccionados, entonces:

Esta es la **distribución hipergeométrica**.

La función que representa esta distribución la podemos analizar de la siguiente manera:

b = **cantidad de componentes en buen estado.**

m = **cantidad de componentes en mal estado.**

$N = m + b$ = **cantidad total de componentes.**

n = **cantidad de pruebas o extracciones.**

Si consideramos C_b^x , nos representa las posibilidades de extraer un componente bueno.

Teniendo en cuenta que de los n componentes extraídos $n - x$ serán componentes en mal estado. Por lo tanto,

C_m^{n-x} nos da las formas posibles de elegir los componentes malos.

Y como ya conocemos C_N^n , nos representa las maneras posibles de elegir n componentes de los N que contamos.

Donde podemos definir ahora la probabilidad de elegir n componentes de las cuales x serán componentes buenas, o sea

$$F(x) = P(X = x) = \frac{C_b^x \cdot C_m^{n-x}}{C_{b+m}^n}$$

La media y la varianza para esta distribución son:

$$\mu = \frac{n \cdot b}{b + m} = \frac{n \cdot b}{N}$$

$$\sigma^2 = \frac{n \cdot b \cdot m \cdot (b + m - n)}{(b + m)^2 \cdot (b + m - 1)} = \frac{n \cdot b \cdot m \cdot (N - n)}{N^2 \cdot (N - 1)}$$

La distribución hipergeométrica es de aplicación en el campo del control de calidad y en problemas de inferencia estadísticas.

FICHA N°22 – Distribución Chi Cuadrado

(Prueba o test Chi-cuadrado)

Supongamos que tenemos una serie de variables aleatorias distribuidas normalmente $Y_1, Y_2, Y_3, \dots, Y_n$ cuyas medias y varianzas son: $E(Y) = \mu$ $Var(Y) = \sigma^2$

estas variables se pueden tipificar como: $X_i = \frac{Y_i - \mu}{\sigma}$

entonces X_i está distribuida normalmente con media y varianza: $E(Y) = 0$ $Var(Y) = 1$

Ahora consideramos la variable aleatoria: $J_i^2 = X_1^2 + X_2^2 + X_3^2 + \dots + X_n^2$

La nueva variable aleatoria forma la denominada distribución Chi-cuadrado o Ji-cuadrado que tiene la siguiente función de densidad:

$$f(J_i)^2 = \begin{cases} \frac{1}{2^{n/2} \Gamma(n/2)} \cdot x^{n/2-1} \cdot e^{-x/2} & \text{para } x \geq 0 \\ 0 & \text{para } x < 0 \end{cases}$$

si tenemos en cuenta que $\tau(x)$ es la función GAMMA y que: $\Gamma(\frac{n}{2}) = (\frac{n}{2} - 1)!$

Por lo tanto, la función de densidad de la distribución Ji-cuadrado será:

$$f(Ji^2) = \begin{cases} \frac{1}{2^{\frac{n}{2}} \cdot (\frac{n}{2} - 1)!} \cdot x^{\frac{n}{2}-1} \cdot e^{-x/2} & \text{para } x \geq 0 \\ 0 & \text{para } x < 0 \end{cases}$$

donde e es el número natural y n es la cantidad de variables aleatorias sumados. Obsérvese que las n variables aleatorias son independientes por lo tanto el sistema tiene n grados de libertad.

Si hay n variables aleatorias, pero solamente h son independientes decimos que existen h grados de libertad.

Se puede comprobar que: $\frac{\sqrt{2 \cdot Ji^2} - \sqrt{2n-1}}{\sqrt{2n-1}}$ está

Para n grande ($n \geq 30$) se puede demostrar que $\frac{\sqrt{2 \cdot Ji^2} - \sqrt{2n-1}}{\sqrt{2n-1}}$ está distribuida normalmente con media 0 y varianza 1.


$$\mu = n$$

$$\sigma^2 = 2n$$

$$M(t) = (1 - 2t)^{-n/2}$$

Uso de la tabla Hi^2

La siguiente figura nos muestra la curva para la distribución de acuerdo a algunos valores de n :




Hallamos de acuerdo a la tabla algunos valores de Hi^2 , para $n=10$ grados de libertad el valor del 20 % del área sombreada en el extremo de la derecha es:

$$P\left(\frac{13,442 < Hi^2 < \infty}{n = 10}\right) = 0,20$$

y para el 30 %

$$P\left(\frac{11,781 < Hi^2 < \infty}{n = 10}\right) = 0,30$$



Propiedad: Naturaleza aditiva de Hi^2 , es una propiedad que tiene cuando Hi_1^2 y Hi_2^2 son independientes y tienen una distribución de Hi^2 con n_1 y n_2 grados de libertad, entonces Hi_1^2 y Hi_2^2 tendrá también una distribución Hi^2 con $n_1 + n_2$ grados de libertad. **Esta propiedad aditiva es válida para k variables Hi^2 independiente.**

Corrección de Yates por continuidad

Para el caso de existir 1 grado de libertad hay tendencia a subestimar la probabilidad, lo que significa que se incrementará la cantidad de rechazos de la hipótesis nula, entonces debemos corregir H_i^2 hacia abajo. Esta corrección se da debido a que la distribución teórica es continua y en nuestros casos prácticos usamos variables discretas. Yates ha demostrado que:

$$H_i^2 = \sum \frac{\left(|k_i - h \cdot p_i| - \frac{1}{2} \right)^2}{h \cdot p_i} \quad \text{para } |k_i - h \cdot p_i| \geq \frac{1}{2}$$

Podemos ver que cuando k (o $k \cdot p_i$) es grande, la corrección de $\frac{1}{2}$ produce un efecto pequeño, pero muy importante cuando k es pequeño. Sin embargo cuando $|k_i - k \cdot p_i|$ es menor que $\frac{1}{2}$, la corrección por continuidad debe suprimirse.

Distribución T de Student

Una distribución de gran importancia es la denominada t de Student que se origina al considerar 2 variables aleatorias U y V , tales que U es una variable normal estandarizada ($\mu = 0$ y $\sigma = 1$) y V se distribuye según H_i^2 con n grados de libertad. Teniendo en cuenta que V es siempre positiva se puede definir otra variable:

$$t = \frac{\sqrt{n} \cdot U}{\sqrt{V}} \quad \text{donde ambas raíces cuadradas se toman positivas.}$$


La función densidad de probabilidades que corresponde a la distribución t con n grados de libertad es:

$$f(t) = \frac{\Gamma\left[\frac{(n+1)}{2}\right]}{\sqrt{(n \cdot \pi)} \Gamma\left(\frac{n}{2}\right)} \cdot \left(1 + \frac{t^2}{n}\right)^{-\frac{(n+1)}{2}} \quad \text{para } -\infty < t < \infty$$

teniendo en cuenta la Función Gamma y su igualdad podemos expresarla:

$$f(t) = \frac{\left[\frac{(n+1)}{2}\right]!}{\sqrt{(n \cdot \pi)} \cdot \left(\frac{n}{2} - 1\right)!} \cdot \left(1 + \frac{t^2}{n}\right)^{-\frac{(n+1)}{2}} \quad \text{para } -\infty < t < \infty$$

Si n es grande ($n \geq 30$) la función $f(t)$ se aproxima estrechamente a la normal. Como lo indica la siguiente figura: Para esta distribución tenemos:



$$\mu = 0 \quad \text{y} \quad \sigma^2 = \frac{n}{(n-2)} \quad (n > 2)$$

Distribución F

Si tenemos 2 variables aleatorias R y S ambas con distribución J_i^2 con m y n grados de libertad respectivamente. Definimos la variable f y a la distribución de dicha variable aleatoria se denomina: **Distribución F**

$$f = \frac{n}{m} \cdot \frac{R}{S}$$

$$f(t) = \frac{\Gamma\left[\frac{(m+n)}{2}\right]}{\Gamma\left(\frac{m}{2}\right) \Gamma\left(\frac{n}{2}\right)} \cdot m^{\frac{m}{2}} \cdot n^{\frac{n}{2}} \cdot f^{\frac{(m-1)}{2}} \cdot (n + mf)^{-\frac{(m+n)}{2}}$$

para $f > 0$

Teniendo en cuenta la función Gamma podemos representar la distribución:

$$f(t) = \frac{\left[\frac{(m-n)}{2}-1\right]!}{\left(\frac{m}{2}-1\right)!\left(\frac{n}{2}-1\right)!} \cdot m^{\frac{m}{2}} \cdot n^{\frac{n}{2}} \cdot f^{\left(\frac{m}{2}-1\right)} \cdot (n+mf)^{-(m+n)/2}$$

La media y la varianza están determinadas por:

$$\mu = \frac{n}{n-2} \quad (n > 2) \quad \text{y} \quad \sigma^2 = \frac{2 \cdot n^2 (m+n-2)}{m(n-4)(n-2)^2} \quad (n > 4)$$

la distribución tiene una moda única en el valor:

$$U_{\text{moda}} = \frac{m-2}{m} \cdot \frac{n}{n+2} \quad (m > 2)$$


En la práctica si S_1^2 y S_2^2 son la varianza de muestras aleatorias independientes de tamaño n_1 y n_2 , respectivamente, tomadas de dos poblaciones normales que tienen la misma varianza, entonces:

$$F = \frac{S_1^2}{S_2^2}$$

Que es el valor de la variable aleatoria que tiene distribución F con parámetros $m=n_1-1$ y $n=n_2-1$ denominados grados de libertad.

La tabla de valores críticos de F solo representa el lado derecho. En caso de que se necesite el valor crítico de la cola izquierda, éste se obtiene calculando el recíproco del valor crítico relacionado que resulta de la tabla. La expresión que refleja esto es:

$$F_{(n,m,1-\alpha)} = \frac{1}{F_{(m,n,\alpha)}}$$



UNIDAD N°4: Estadística

FICHA N°23 – Estadística, etapas de la investigación científica

INTERPRETACION CONCEPTUAL

La mayoría de las personas entiende por Estadística como columnas de cifras o gráficos. Este concepto se asemeja a la definición tradicional de Estadísticas: "La compilación, organización, resumen, presentación y análisis de datos numéricos".

La función principal de la Estadística es elaborar principios y métodos que nos ayuden a tomar decisiones frente a la incertidumbre, por lo cual decimos que es el **METODO DE TOMA DE DECISIONES FRENTE A LA INCERTIDUMBRE**.

ESTADISTICA es un método que, a través de la recolección en masa y el agrupamiento racional de los hechos, permite reseñar y observar los fenómenos colectivos, obtener relaciones numéricas sensiblemente independientes de las anomalías del azar y poner de manifiesto la regularidad de las variaciones.


La Estadística puede dividirse en dos ramas:

1. **Estadística Descriptiva o Análisis Exploratorio:** referida a la recolección y descripción de datos.
2. **Estadística Inferencial o Análisis Confirmatorio:** referida al proceso de utilización de los datos muestrales para la toma de decisiones, que puedan ser extendidos a la población de la cual forman parte los datos analizados.

DATOS ESTADISTICOS

Para cumplir con este requisito debe ser un conjunto o conjuntos de números que presenten relaciones significativas; es decir que datos estadísticos son números que pueden ser comparados, analizados e interpretados.

Los datos estadísticos pueden ser considerados como:



α) CUANTITATIVOS (variables cuantitativas o variables) son aquellos que arrojan respuestas numéricas, es decir que pueden ser transformadas en datos numéricos simplemente por medición directa de unidades, tales como pulgadas, calorías, peso, etc. Se presentan a través de series llamadas **Distribuciones de frecuencias**.

Los valores de las observaciones cuantitativas, se conocen como los valores que una variable puede asumir. La amplitud de una variable es un conjunto de valores individuales de un fenómeno dado, que, a su vez, son los valores de las observaciones cuantitativas.

Una variable puede ser:

1. **Discreta:** son respuestas numéricas que surgen de un proceso de conteo, es decir la unidad de medida no es divisible, sólo puede ser definida en términos enteros o ciertos valores fraccionarios especificados.
2. **Continua:** son respuestas numéricas que surgen de un proceso de medición. Puede asumir cualquier valor numérico (cualquier número real) dentro de una amplitud específica. En tal serie, los valores sucesivos pueden diferir en cantidades infinitesimales. Una serie continua es aquella en la que las unidades pueden dividirse en fracciones de cualquier tamaño, por pequeñas que sean, de modo que haya un flujo continuo de valores con graduaciones infinitamente pequeñas.

La estatura de una persona es un ejemplo de variable continua, ya que la respuesta puede tomar cualquier valor dentro de un intervalo, según sea la precisión del instrumento de medición. Es interesante observar que mientras el peso, la longitud, la altura, el tiempo y la temperatura son variables continuas, sus mediciones son discretas, porque el instrumento de medición tiene algún límite de precisión.

Para cálculos y análisis estadísticos a menudo hallamos conveniente considerar tales variables como continuas.

b) **CUALITATIVOS** (variables cualitativas o atributos) son aquellos que arrojan respuestas categóricas, se describen por palabras. Los individuos son o no poseedores, de cierta cualidad o propiedad. Ejemplo: sexo, nacionalidad, estado civil, etc.

Pero las observaciones cualitativas, es decir los atributos, a menudo pueden ser expresadas numéricamente. En el proceso de enumerar, asignamos 1 a un elemento que tiene el atributo y 0 a un elemento que carece de él.

ETAPAS DE LA INVESTIGACIÓN CIENTÍFICA

En Estadística, como método para analizar la información, es necesario cumplimentar con una serie de etapas a los fines de lograr resultados congruentes, homogéneos y fáciles de interpretar.

Para ello consideraremos cinco etapas:

- 1^{ra}. Etapa : **Formulación o definición de problema.**
- 2^{da}. Etapa : **Diseño de experimento.**
- 3^{ra}. Etapa : **Recopilación.**
- 4^{ta}. Etapa : **Clasificación, tabulación y descripción de los resultados.**
- 5^{ta}. Etapa : **Generalización o Inferencia final.**

1ra. Etapa: Formulación o definición del problema

La primera tarea es **conocer exactamente que ha de ser investigado**, es decir, formular el problema o pregunta lo más precisamente posible. Sólo entonces puede decidir el investigador, sobre **cuales datos son relevantes al problema**. La calidad de las conclusiones estadísticas, depende de la corrección y precisión de los datos, que a su vez depende de la exactitud en la formulación del problema. Las técnicas estadísticas, por muy refinadas y precisas que sean, no pueden ayudar a alcanzar decisiones si son aplicadas a datos inapropiados.

2da. Etapa: Diseño del Experimento

Una vez formulado con precisión el problema que requiere análisis estadístico, el investigador debe decidir, **si estudia toda la población o sólo una parte extraída de ella (muestra)**. El estudio de una población se llama ENUMERACION COMPLETA O CENSO, **el estudio de una muestra se conoce como MUESTREO**. En la práctica es a menudo costoso, lento o aun físicamente imposible efectuar un censo, entonces tenemos que recurrir al muestreo. A través de la muestra inferimos sobre la población de la cual ha sido extraída, por lo tanto, la muestra debe representar adecuadamente a la población.

Hay muchos tipos de diseño de muestreo, cada uno tiene sus méritos, según el tipo de población y el objetivo del estudio: Muestreo al Azar, Estratificado, Sistemático y Por Conglomerados.

Generalmente emplearemos muestras al azar, o sea donde **probabilidad de elección** de cada elemento de la población es conocida.

3ra. Etapa: Recopilación de Datos Estadísticos

a) Relevamiento Estadístico

Se refiere, a los métodos usados para obtener información pertinente de las unidades elementales introducidas en una muestra o incluidas en un censo. En otras palabras, es aquella etapa que tiene por objeto, la extracción y recolección de datos a partir de las fuentes que lo suministran.

Existen tres métodos básicos con los cuales el investigador puede obtener los datos deseados.

1- Uso de fuentes con datos publicados:

Esta posibilidad nos lleva a considerar los datos en:

- **Internos:** se obtiene dentro de la organización que realiza el estudio estadístico.
- **Externo:** o publicados, se obtiene de distintas fuentes de información, tales como: Organismos Nacionales e Internacionales, Publicaciones Nacionales e Internacionales.

Existen dos clases de fuentes de datos publicados:

- **Primarias:** cuando los datos se obtienen de la publicación editada por el recopilador original de los mismos.
- **Secundarias:** cuando los datos son obtenidos de una reimpresión, la cual es publicada por una organización distinta del recopilador original.

2- Diseñar un experimento

Un experimento diseñado es una prueba o serie de pruebas en las cuales se inducen cambios deliberados en las variables de entradas de un proceso o sistema de manera que sea posible observar e identificar las causas de los cambios en la respuesta de salida. La técnica para realizar un correcto diseño experimental suele ser materia para cursos más avanzados, ya que a menudo implican procedimientos estadísticos sumamente complejos.

3- Efectuar una encuesta

El método de reunir datos de poblaciones no humanas a menudo es sencillo y directo. Así, al estudiar si la longitud de determinados tornillos está dentro de ciertos límites, sólo necesitamos medirlos.

Los datos sobre poblaciones humanas pueden ser compilados haciendo observaciones directas o formulando preguntas. En general, un método es considerado el mejor en un estudio determinado, si obtiene la información necesaria con la misma precisión, con los costos más bajos y en cualquier tiempo.

En cualquiera de los métodos el primer paso es planear el cuestionario.

Deben tenerse presente algunos principios generales de buena técnica de interrogación:

- 1- Las preguntas deben formularse sencilla y claramente.
- 2- Sólo pueden formularse preguntas que el interrogado pueda responder correctamente, las preguntas deben ser formuladas para reducir la respuesta emocional y la turbación. También, es de utilidad, asegurar al interrogado que la información permanecerá completamente confidencial.
- 3- Las preguntas deben ser formuladas lógicamente y ordenadas de modo que faciliten la tabulación de las respuestas.

La combinación de encuestas por correo y entrevista personal es el mejor método y el más económico.

b) Población y Muestra

A fin de entender cómo se pueden aplicar los métodos estadísticos, se debe **distinguir entre POBLACION Y MUESTRA**.

Una **POBLACION O UNIVERSO** es la totalidad de artículos o cosas a considerar. Es el conjunto de datos individuales de personas o cosas, acerca de las cuales se desea información.

Los integrantes de una población se denominan elementos y en sentido estadístico pueden ser de existencia real (automóvil, persona, casa, etc.) ó abstracta (temperatura, voto, etc.).

Los elementos pueden:

- a) Coincidir con unidades naturales, como obreros, turistas, neumáticos.
- b) Ser creados artificialmente con el propósito de la investigación.

Respecto del tamaño de la población, esta puede ser.

1. Infinita: Comprende un número infinitamente grande de unidades elementales.
2. Finita: No es indefinidamente, o sólo contiene un número finito de datos.

Es de fundamental importancia en toda investigación definir concreta y precisamente la población motivo de análisis.

Una **MUESTRA** es la parte de la población que se ha seleccionado para el análisis. Una medida de resumen que se calcula para describir una característica de la totalidad de una población; se llama PARAMETRO, y aquella que se calcula para describir una característica de sólo una muestra de la población se llama ESTADIGRAFO.

c) Unidad Estadística y Unidad de Relevamiento

- **Unidad Estadística:** Constituida por cada uno de los elementos individuales que en forma conjunta constituyen la población sobre la que se quiere realizar un relevamiento, en otras palabras, dentro de un levantamiento estadístico es el elemento del conjunto o universo sobre el cual queremos hacer análisis o sobre el cual queremos determinar un cierto atributo.
- **Unidad de Relevamiento:** Formada por unidades estadísticas. Es hacia donde vamos a obtener el dato.

d) Relevamiento estático y dinámico

En un **relevamiento estático**, los datos son obtenidos a una fecha determinada, en un día fijo, obteniéndose en ese día todos los datos necesarios para la investigación. Ejemplo: Censo

En un **relevamiento dinámico**, los datos corresponden a aquellas operaciones que se realizan en forma continuada a través del tiempo y de forma sistemática, no en un solo día, sino en forma sucesiva. Ejemplo: Datos sobre nacimientos, defunciones, casamientos, etc.

Considerando los anteriores conceptos, podemos dividir en dos a los métodos de captación de la información:

1- Método de captación completo o exhaustivo:

- a) Censo o relevamiento estático: consiste en estudiar a la población a través de todos sus elementos en un momento determinado. Ejemplo: Censo Ganadero, Censo Poblacional.
- b) Registro exhaustivo o relevamiento dinámico: consiste en estudiar en forma continua a todas las unidades estadísticas. Ejemplo: Registro Civil, Registro Prendario, Registro del Automotor.

Cuando resulta oneroso o imposible de realizar por ser un colectivo infinito, o cuando la provocación del dato produce destrucción de los elementos, recurrimos a la muestra, a través de:

2 -Método de Captación parcial, consiste en tomar información sobre una parte representativa de la población que constituye la muestra.

4ta. Etapa: Clasificación, tabulación y descripción de los resultados

Se refiere a la organización y descripción de los datos recopilados, a los fines de facilitar la interpretación y el análisis de los mismos.

Cuando los datos con los que se cuenta, son pocos, es posible presentar la información en forma de explicación escrita, llamada presentación literal. Pero cuando se trabajó con un gran número de datos se hace necesaria la presentación en forma ordenada, lográndose tal objetivo al clasificarlos de manera sistemática y presentarlos en un cuadro o bien construyendo gráficos y diagramas.

Si se ha trabajado con una muestra, las medidas basadas en sus datos se llaman ESTADISTICAS O ESTADIGRAFOS, mientras que si las medidas resumen todos los datos que integran la población, se llaman PARAMETROS.

Esta cuarta etapa corresponde a la Estadística Descriptiva, referida según dijimos con anterioridad, a la recolección y descripción de datos.

5ta. Etapa: Generalización o Inferencia Final

Si se ha trabajado con la totalidad de los elementos (censo o enumeración completa), una encuesta termina con estadísticas descriptivas (etapa anterior). Entonces, puede describirse y revelarse las características de toda la población pudiendo tomarse fácilmente una decisión sobre el problema.

Es importante aclarar que aún con un censo puede obtenerse una estimación, en lugar del verdadero valor, debido a errores, falta de respuestas, etc.

Si, por el contrario, el estudio se realizó en base a una muestra es necesario una etapa adicional que consiste en tratar de responder basándose en las estadísticas de la muestra, al problema o la pregunta original formulada, que siempre se refiere a los parámetros de población.

Esto se denomina **Estadística Inductiva o Inferencia Estadística**; referida, según se dijo con anterioridad, al **proceso de utilización de los datos muestrales para la toma de decisiones**, que puedan ser extendidas a la población de la cual forman parte los datos analizados.

ORGANIZACION Y PRESENTACION DE DATOS ESTADISTICOS

Tablas estadísticas

Como mencionamos, es necesaria la organización de los datos captados a los fines de poder interpretarlos para la toma de decisiones.

Para ello contamos con tres formas de presentación:

1. Literal: aplicable cuando el número de datos, es pequeño entonces se expresan en forma escrita.
2. Tablas Estadísticas.
3. Gráficos estadísticos.

Las restantes formas, son utilizadas cuando el número de datos con los que se trabaja es grande, y de no resumirlos se complica su análisis.

Tipos de tablas: De acuerdo con los propósitos para las cuales fueron creadas:

- a) **Tablas para propósitos generales o de referencia:** no se construyen con un fin específico, sino que proporcionan información que puede ser usada como referencia o uso general.
- b) **Tablas para propósitos especiales o de resumen,** analíticas o de texto: se confeccionan con el fin de proporcionar información para una exposición particular.

Partes principales de una tabla:

- a) **Títulos:** es una descripción del contenido de la tabla. Debe ser preciso y completo.

- b) **Encabezamiento:** Es la parte superior de las columnas, se colocan los títulos que indican los conceptos y los datos presentados en la tabla. En algunos casos existen encabezamientos y subencabezamientos.
- c) **Conceptos o columna matriz:** Descripciones que aparecen en las hileras de las tablas, en el extremo izquierdo de las mismas.
- d) **Cuerpo:** Está formado por el contenido de los datos estadísticos, los que están agrupados de acuerdo con las descripciones o clasificaciones de los encabezamientos y conceptos.
- e) **Notas del encabezamiento:** Se ubican sobre los encabezamientos y debajo del título, y aclaran ciertos aspectos relacionados con la tabla que no han sido incluidos en el título, ni en los encabezamientos, ni en los conceptos.
- f) **Nota al pie:** Debajo del cuerpo de la tabla se ubican las notas al pie, que sirven para clarificar algunos aspectos incluidos y que no son explicados en otras partes de la tabla.
- g) **Fuente:** Debajo de las notas al pie, se establece la fuente que sirvió para obtener la información proporcionada por la tabla.

DISTRIBUCIONES UNI, BI y MULTIDIMENSIONALES

Las distribuciones denominadas **unidimensionales**, son aquella que sólo analizan una variable por vez, por ejemplo, peso de las personas.

Existen, además: -

- **Distribuciones bidimensionales:** es decir, las que analizan dos variables, como, por ejemplo, relación entre peso y altura de las personas.
- **Distribuciones multidimensionales:** cuando se analizan dos o más variables por vez, como, por ejemplo, relación entre peso, altura y edad de las personas.

Insistamos en que una variable es una cantidad que varía. Una característica es **la distribución entre lo discreto y continuo**, ya analizados. Pasaremos a continuación a estudiar las formas con las que contamos a los fines de la presentación de los datos brutos en tablas y gráficos (etapa cuarta de la Investigación Científica), para lo cual tendremos en cuenta:

- Si la variable es discreta o continúa, y
- La cantidad de datos que constituyen la serie a analizar.

Series Simples: Se utilizan cuando la serie de datos con que contamos es pequeña, y en general todos los valores son distintos, es decir que se presenta cada uno de ellos una sola vez. Cada valor de la serie representa una observación.

Pero cuando el número de datos es muy grande, el simple análisis de ellos no nos permite obtener ninguna conclusión de interés. Es por ello que prácticamente todo el análisis de los datos se practica a través **de tablas que se conocen como Distribuciones de Frecuencia, cuyo objeto es condensar y simplificar los datos sin perder muchos detalles.**

FICHA N°24 – Distribución de frecuencias discretas y continuas

Distribuciones de frecuencias de variables discretas

Cuando el número de datos recopilados es grande, se hace indispensable **agrupar los valores de los mismos con el fin de facilitar el análisis estadístico**. La agrupación de datos, también llamada distribución de frecuencia, son datos ordenados y están clasificados cuantitativamente.

Este ordenamiento puede ser de magnitud ascendente o descendente, y pueden existir valores repetidos y cuando se especifican dichas repeticiones se obtiene una distribución de frecuencia y el número que indica las veces que se repite un valor se denomina frecuencia.

Simbolizaremos con y_i ($i = 1, 2, \dots, m$) a los valores observados distintos, donde m representa el número de estos valores. Este valor de m será siempre menor que n , ya que hemos representado con n el número total de observaciones.

Frecuencias absolutas: Es el número de veces que se repiten los valores distintos de la variable y se simboliza por n_i ($i = 1, 2, \dots, m$). Esta frecuencia absoluta necesariamente será menor o a lo sumo igual que n , número total de frecuencias ($n_i \leq n$), y mayor o igual a 0 ($n_i \geq 0$).

La suma de todas las frecuencias absolutas es igual al tamaño de la muestra o total de observaciones

y_i	n_i
y_1	n_1
y_2	n_2
$\vdots$	$\vdots$
y_m	n_m
$\sum_{i=1}^m n_i = n$	

Frecuencias relativas

Es el cociente que se obtiene al dividir el valor de cada frecuencia absoluta (n_i) por el total de observaciones (n).

La simbolizamos por: $h_i = \frac{n_i}{n}$ ($i = 1, 2, \dots, m$).

El resultado es una fracción que no puede ser mayor que 1 ($h_i \leq 1$), ni menor que 0 ($h_i \geq 0$), y la suma de todas las frecuencias relativas es siempre igual a 1

y_i	h_i
y_1	h_1
y_2	h_2
$\vdots$	$\vdots$
y_m	h_m
$\sum_{i=1}^m h_i = 1$	

Frecuencias acumuladas: Tanto las frecuencias absolutas como las relativas pueden ser acumuladas, es decir se irán sumando los distintos valores hasta el correspondiente subíndice de la variable.

a) **Frecuencia absoluta acumulada** La simbolizaremos por N_i ($i = 1, 2, \dots, m$), valor que corresponde a y_i siendo por definición: $N_i = n_1 + n_2 + \dots + n_i$

Entonces, la primera acumulada será $N_1 = n_1$, la segunda $N_2 = n_1 + n_2$, la tercera $N_3 = n_1 + n_2 + n_3$ y así sucesivamente hasta la última $N = n$.

b) **Frecuencias relativas acumuladas** La simbolizaremos por H_i ($i = 1, 2, \dots, m$) valor que corresponde a y_i , siendo por definición: $H_i = h_1 + h_2 + \dots + h_i$

Entonces la primera frecuencia relativa acumulada será $H_1 = h_1$, la segunda será $H_2 = h_1 + h_2$, la tercera será $H_3 = h_1 + h_2 + h_3$ y así sucesivamente hasta la última $H_m = 1$.

y_i	N_i	H_i
y_1	$N_1 = n_1$	$H_1 = h_1$
y_2	$N_2 = n_1 + n_2$	$H_2 = h_1 + h_2$
$\vdots$	$\vdots$	$\vdots$
y_m	$N_m = n$	$H_m = 1$
$\sum_{i=1}^m n_i = n$		$\sum_{i=1}^m h_i = 1$

Distribuciones de frecuencias de variables continuas

Cuando el número de observaciones es grande y el número de posibles clases de descripción es casi tan grande como el total de observaciones, (cuando los valores distintos de la variable son casi tan grandes como el total de valores observados), el recorrido de las variables ya no puede ser descrito por unas pocas categorías distintas de medidas (variable discreta). Por otra parte, si la variable es de las consideradas continuas (puede asumir cualquier valor real dentro de un intervalo) es común presentar estas distribuciones de forma distintas a las ya analizadas, en donde se va a confeccionar la distribución de frecuencias, pero en lo que se llama SERIE AGRUPADA DE DATOS:

Quiere decir que los distintos valores que presenten la variable no representarán los distintos valores individuales como sucedía hasta ahora, sino que serán grupos de valores llamados **Clases**.

Conceptos a utilizar:

- 1- **INTERVALOS DE CLASE:** Los valores de la variable aparecen separados en intervalos de clase, es decir que, para condensar y simplificar los datos, se utilizan las tablas de distribución de frecuencias, en las cuales se agrupan convenientemente los valores de la variable, en intervalos. Simbolizaremos a los intervalos de clases por $y'_{i-1} - y'_i$, donde y'_{i-1} es el extremo inferior o límite inferior del intervalo, es decir los números que aparecen a la izquierda y y'_i es el extremo superior o límite superior, es decir los números que aparecen a la derecha.

2- **AMPLITUD DEL INTERVALO:** Hace referencia a la diferencia entre los valores extremos del intervalo.

Lo simbolizamos por $oi = y'_i - y'_{i-1}$

Su tamaño depende del problema analizado y también del interés del investigador en condensar más o menos esos datos. Cuanto menor sea la amplitud del intervalo mayor será la cantidad de clases que tendremos, y viceversa. A medida que los datos se agrupan se va perdiendo no sólo información, sino precisión en los resultados

3- **MARCAS DE CLASE:** Son los puntos medios del intervalo.

Los simbolizamos por y_i y las definimos como la media aritmética de los valores extremos del intervalo.

$$y_i = \frac{y'_{i-1} + y'_i}{2}$$

4- **RECORRIDO DE LA SERIE:** Diferencia entre el valor superior (I_2) y el valor inferior (I_1) de la serie. Es decir: $R = I_2 - I_1$.

Al construir los intervalos de clase se amplía el recorrido para evitar que los límites inferior y superior coincidan con los valores extremos que adopta la variable y por convención se establece: **"Si un valor de variable cae en el extremo superior de un intervalo, corresponde al intervalo siguiente"**.

Tablas de distribución de Frecuencias para Variables Continuas.

Int. de clase	Marcas de clase	Frecuencia Absoluta	Frecuencia Relativa	Frec. Absoluta Acumulada	Frec. Relativa Acumulada
$y'_{i-1} - y'_i$	y_i	n_i	h_i	N_i	H_i
$y'_0 - y'_1$	y_1	n_1	h_1	N_1	H_1
$y'_1 - y'_2$	y_2	n_2	h_2	N_2	H_2
$y'_2 - y'_3$	y_3	n_3	h_3	N_3	H_3
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$y'_{m-1} - y'_m$	y_m	n_m	h_m	N_m	H_m
		$\sum_{i=1}^m n_i = n$	$\sum_{i=1}^m h_i = 1$		

FICHA N°25 – Representaciones graficas de las distintas variables


Veremos a continuación los gráficos posibles que podemos construir tanto para variables discreta como para variables continuas.

25.1 Gráficos Lineales

1-Gráfico de Bastones o Espectro:

Utilizamos esta gráfica cuando tenemos unos pocos valores distintos correspondientes a una **serie discreta**.

Consisten en líneas o segmentos de líneas. Para su construcción trabajaremos con el cuadrante positivo de un sistema de coordenadas cartesianas ortogonales, cuyos ejes "x" e "y" deberán ser rotulados claramente. Convenimos que el eje "x" representará los valores de la variable y el eje "y" los valores correspondientes a las frecuencias, ya sean absolutas (n_i) o relativas (h_i), según se elija una u otra.



La **altura de estas ordenadas o bastones, nos indican las frecuencias absolutas o relativas**, ya que es indistinto el valor que tomemos en la ordenada si las escalas son proporcionales a los valores que representan.


Zoy Eder, Pairetti Franca

2-Gráfico Acumulativo de Frecuencias

Si se consideran las frecuencias absolutas o relativas acumuladas, la representación para el caso de una **variable discreta**, se efectúa mediante el gráfico Acumulativo de Frecuencias.

Al igual que para la construcción del gráfico anterior, utilizaremos el cuadrante positivo de un sistema de coordenadas, cuyos ejes deberán ser rotulados claramente.

También convendremos en que el eje "x" representará los valores de la variable, y el eje "y" mostrará ahora la frecuencia acumulada absoluta (N_i) ó relativa (H_i). Luego de marcar sobre el eje horizontal los valores de la variable, se levanta en cada uno de estos puntos una vertical de longitud igual a la frecuencia acumulada respectiva, completando con tramos horizontales la parte de los intervalos en que no se prestan observaciones, quedando indicado una línea poligonal en escalera.



25.2 Gráficos de Superficie

1-Histograma



Características especiales para su construcción:

- 1- Las frecuencias de clase suelen representarse en función del eje y y la escala de los intervalos de clase en el eje x. Los ejes x e y deben comenzar en 0, con interrupciones de escala si son necesarias. Esta recomendación no es necesaria para el eje x. Pero ambos ejes deben ser rotulados, clara y completamente.
- 2- Un espacio de la mitad al tamaño completo del intervalo de clase, se deja en cada extremo del eje x.
- 3- Las designaciones de escala x suelen ser colocadas como los verdaderos límites de clase. Las barras deben tocarse unas con otras, sin brechas, excepto para clases vacías. A veces, se rotula la escala x colocando el valor medio de cada clase en el centro de la base de la barra.
- 4- La escala x, es igualmente espaciada cuando los intervalos de clase son uniformes. En una distribución donde los intervalos son variables, la escala x debe ser ajustada apropiadamente.
- 5- El eje y debe ser completamente rotulado para mostrar si representa frecuencia o densidad de frecuencia.
- 6- Un histograma se representa siempre como compuesto de barras, tanto si se muestra explícitamente como si no se muestran.

Entonces, se construye utilizando un segmento de la escala horizontal para representar cada intervalo de clase, eligiendo un rectángulo igual en altura a la frecuencia absoluta o relativa ó densidad correspondiente a esa clase.

Polígono de frecuencias: Hacemos esto si disponemos de un histograma, trazando simplemente un punto sobre el punto medio de la parte superior de cada barra del histograma y uniendo esos puntos por líneas rectas.

Con mucha frecuencia, se construyen sin trazar los rectángulos. Sin el histograma obtenemos el polígono localizando las coordenadas:



las ordenadas (y_i) que son las frecuencias de clase, y las abscisas, que son los puntos medios. Estos puntos son unidos después por líneas rectas.

No representa muy bien los datos básicos. La diferencia más notable es que las áreas situadas debajo de él generalmente no son proporcionales a las frecuencias. Un remedio es cerrar el polígono en la base prolongando ambos extremos de la curva hasta los puntos medios de dos clases hipotéticas situadas en los extremos de la distribución que tienen frecuencias 0 (se deja indicado en el gráfico, con igual número las áreas que compensan).

Ventajas de usar el Polígono:

1- Cuando han de compararse varias distribuciones sobre el mismo gráfico, es mucho más claro superponer polígonos que histogramas, especialmente cuando todas las distribuciones tienen los mismos límites de clase.

2- El polígono sugiere el empleo de una curva suave como una representación idealizada de la distribución de la población. Una muestra consta de sólo un número limitado de unidades, por lo que su distribución se caracteriza por irregularidades.

Sin embargo, si las unidades de la muestra se incrementan y la amplitud de los intervalos se disminuye continuamente, podemos esperar que la distribución sea cada vez más suave y cada vez más regular, porque las irregularidades que afectan a una pequeña cantidad de datos, serían eliminadas gradualmente.

Curva Suave

Cuando la muestra es muy grande, los intervalos de clase son muy estrechos (casi muy pequeño), pero cada uno contendrá un número sustancial de unidades. Al mismo tiempo si la escala vertical que mide la frecuencia, es reducida de modo que el área del histograma para esta muestra extraordinariamente grande sea igual al área de la pequeña muestra original, el histograma de la muestra grande formará prácticamente una curva suave.

La **curva suave adquiere importancia porque se considera que representa la verdadera distribución de la población de la que se extrae la muestra.** Pero la derivación de una curva suave ampliando la muestra, es generalmente una imposibilidad práctica. Lo que solemos hacer, es aproximar la distribución de la población sobre la base de los datos de la muestra.

Esto podemos hacerlo suavizando las puntas del polígono de frecuencia dibujando a mano o introduciendo una curva suave a los datos de la muestra con alguna fórmula matemática.

Debido a la sorprendente libertad para ajustar la curva, la curva suave debe presentarse siempre con el histograma.

Son llamadas alternativamente **MODELOS DE POBLACION**, porque describen las características importantes de las distribuciones de población.

Hay otras razones para nuestro interés por los Modelos de Población:


- 1- Es necesario para la toma de decisiones.
- 2- Las inferencias estadísticas a menudo requieren que conozcamos modelos de población.
- 3- Un modelo de población, estando representado por una curva suave, a veces se presta más fácilmente a un tratamiento matemático.

Algunos modelos de población son:





a) **Tiene forma de campana.** Las densidades de frecuencia más grande están en el centro. Hay densidades muy pequeñas en ambos extremos.

Es una distribución simétrica, llamada **Curva de Distribución Normal o Curva Normal**.



b) **Distribución Bimodal.** Significa que tiene dos picos. Este tipo de distribución, aparece cuando una población contiene ciertos elementos que pueden ser divididos en dos clases que difieren entre sí en las características que se miden. La población no homogénea.



Modelos de distribuciones asimétricas. Generalmente tienen un solo pico situado en el extremo inferior o superior de la curva.



c) Cuando la cola más larga está a la derecha (c), decimos que la distribución es asimétrica a la derecha o positivamente asimétrica.

d) Cuando la cola más larga está a la izquierda (d), distribución es asimétrica a la izquierda o negativamente asimétrica.

e) Describe una distribución que contiene predominante valores bajos y altos, siendo relativamente escasos los valores intermedios.




Curva en forma de J ó J invertida, en que las frecuencias de ocurrencia aumentan o disminuyen continuamente a lo largo de la escala horizontal.

Si bien la mayor parte de las veces no conocemos las verdaderas distribuciones de población, podemos aproximar sus modelos trazando una curva suave a los datos de la muestra o por puro razonamiento deductivo.

Diagrama Escalonado

Representa a una distribución de frecuencias acumuladas, mediante una serie de Líneas horizontales en las correspondientes clases, a la altura de las respectivas frecuencias, con las coordenadas que presentan las escalas de las mismas formas que para histogramas.

Los puntos finales de las líneas horizontales, pueden ser unidos o no por líneas verticales.




FICHA N°26 – Ojivas y gráficos especiales**Ojiva**

Es un polígono que representa una distribución acumulada en forma de un diagrama de líneas.

Puede ser:

- **Ojiva Mayor que:** En el caso "Menor que", las frecuencias son acumuladas de valores menores a mayores, y por consiguiente se conocen como límites de clase superior, y_i .
- **Ojiva Menor que:** En caso "Más que", las frecuencias son acumuladas usando los límites de clase inferior, y_{i-1} como referencia.



Una ojiva se usa principalmente para **interpolaciones**, que pueden hacerse de dos modos:

1. Si se escoge un punto de la escala horizontal, el número o proporción correspondiente de observaciones en la distribución cuyos valores son iguales o menores que el valor indicado por el punto escogido, pueden encontrarse en la escala vertical.
2. Esta vez, nos desplazamos del eje vertical al eje horizontal para hallar el valor debajo del cual encontraremos un número, o proporción dado de observaciones. Supongamos que trabajamos una línea horizontal desde 10 para que corte la ojiva y, luego, bajamos una perpendicular de la intersección a la escala horizontal (70). Esto significa que 10 observaciones de la muestra tienen valores iguales o menores de 70 (ó también 10 tienen valores iguales o mayores de 70).

Un valor como este que divide toda la serie en dos partes iguales, se llama mediana.


Se trabaja con frecuencias absolutas o relativas acumuladas. Se comienza al inicio de cada intervalo. No se trabaja con puntos medios.

Curva Acumulativa Suavizada

También un Diagrama o una Ojiva, pueden ser suavizados para representar una Distribución de Población.

Formas:

- a) Distribución Uniforme, b) Distribución en forma de Campana, c) Distribución Positivamente Asimétrica, d) Distribución Negativamente Asimétrica



Gráficos especiales

1- Diagrama de tallo y hojas

Si consideramos que se ha realizado un estudio en 15 industrias manufactureras de Estados Unidos, analizando el porcentaje de inversiones totales en plantas y equipos destinado al control de la contaminación, arrojando los siguientes datos: 17, 02, 07, 04, 08, 17, 04, 04, 14, 03, 03, 02, 04, 10, 01 (Fuente: World Almanac and Book of Facts, 1979).

Podemos tener un cuadro mucho más informativo si confeccionamos un diagrama de tallo y hojas. En este caso tomamos como tallo el dígito de la izquierda y como hojas los dígitos de la derecha.

```

0 | 2 4 4 4 3 3 2 4 1
0 | 7 8
1 | 4 0
1 | 7 7
  
```

Sin ordenar

```

0 | 1 2 2 3 3 4 4 4 4
0 | 7 8
1 | 0 4
1 | 7 7
  
```

Ordenado

2- Barra Porcentual

Se representa mediante un rectángulo horizontal, donde la superficie del rectángulo representa el 100% del fenómeno analizado.


Para construir el gráfico, se utiliza una regla de tres simple que nos permite determinar los distintos valores de las áreas correspondientes de la barra.

Universidad Estatal

Aplicación de Ingresos (1)	Porcentaje (2)	cms. (3)
Sueldos Docentes	3000	30
Sueldos no Docentes	2000	20
Otros	5000	50
	10000	100

Universidad Privada

Aplicación de Ingresos	Porcentaje	cms.
Sueldos Docentes	5500	37
Sueldos no Docentes	4000	27
Otros	5500	36
	15000	100




Luego, podemos comparar dentro de cada barra y entre barras.

3- Diagrama Circular (diagrama de sectores):

También indica porcentajes del fenómeno estudiado.


Diagrama Circular
de aplicación de los ingresos en la U. Estatal



4- Gráfico de Zonas (diagramas de áreas):

Sirve para representar en un mismo gráfico varios fenómenos con el fin de compararlos entre sí. Se utiliza muy frecuentemente en series cronológicas que analizan aspectos que ocurren a través del tiempo.

Años	Cant. Lineas	Cant. Celular
Enero	5.875.665	247.008
Febre	5.932.610	255.325
Marzo	5.989.556	264.747
Abril	6.097.460	270.031
Mayo	6.205.364	278.588
Junio	6.313.267	291.710
Julio	6.299.748	309.039
Agos.	6.286.229	323.207
Septi.	6.362.352	340.743
Octu.	6.470.786	360.529
Novi.	6.509.151	382.848




5- Gráfico de Caja:

Este tipo de gráfico depende de determinada característica numérica de los datos que son la mediana, los cuartiles y la amplitud.

La **Mediana** (Q_2) de n observaciones es el número que ocupa el lugar $(n+1)/2$ cuando se ordenan las observaciones desde la más pequeña hasta la mayor. La mediana divide el conjunto de datos en la mitad y a veces es conveniente dividir cada mitad a la mitad también, para de esta manera determinar los **cuartiles**. Se puede decir que el cuartil inferior (Q_1) es la mediana de la mitad inferior de los datos, y el Cuartil superior (Q_3) es la mediana de la mitad superior de los datos.

La **Amplitud** de un conjunto de observaciones es la diferencia entre la mayor y menor observación.



RESUMEN DE GRAFICOS

Resumen de gráficos:

1- Gráficos Lineales, para Variables Discretas.

- 1.1. Gráficos de Bastones, para frecuencias absolutas y relativas.
- 1.2. Gráficos Acumulativo de Frecuencias, para frecuencias acumuladas.

2- Gráficos de Superficie, para Variables Continuas.

- | | | |
|-------------------------------|---|--|
| 2.1. Histograma. | } | Para frecuencias absolutas y relativas |
| 2.2. Polígono de Frecuencias. | | |
| 2.3. Curva Suavizada. | | |
| 2.4. Diagrama Escalonado. | } | Para frecuencias acumuladas. |
| 2.5. Ojiva Mayor y Menor que. | | |
| 2.6. Curva Acumulada. | | |

3- Gráficos Especiales

- 3.1. Diagrama de tallo y hoja.
- 3.2. Barra Porcentual.
- 3.3. Círculo Radiado.
- 3.4. Gráfico de Zonas.
- 3.5. Gráficos de Cajas.

FICHA N°27 – Medidas de dispersión o concentración

Los parámetros o estadígrafos de posición no son suficientes para caracterizar totalmente una cierta distribución de frecuencias ya que los valores incluidos en grupo de datos en general varían significativamente en magnitud; es decir algunos de ellos son pequeños y otros grandes, estableciéndose lo que se llama la dispersión o la concentración de los valores.


Dos o más conjuntos de datos pueden diferir tanto en tendencia central como en dispersión o pueden tener las mismas medidas de tendencia central, pero pueden tener grandes diferencias en términos de dispersión.

Las figuras A), B) y C), si bien, son iguales en cuanto a su promedio, los datos en C) están más concentrados alrededor del promedio que la figura B) y los de ésta más que los de la figura A) o dicho de otro modo los datos de la figura A) están más dispersos que los de la figura B) y estos más que los de la C).

Una medida de dispersión es importante por dos razones:

1- Indica el **grado de variación** entre los valores de la serie de datos recopilados.

2- La medida de dispersión es utilizada como complemento de la medida de posición para caracterizar un conjunto de datos o para compararlos con respecto a otro conjunto cualquiera.



Cuando la dispersión es grande, el promedio tiene muy poca significación, en cambio si la dispersión es baja, es decir los datos están muy concentrados alrededor del promedio, éste se vuelve altamente significativo, ya que en este caso la medida de posición corresponde a un valor muy representativo del conjunto.

Recorrido (Amplitud, campo de variación): Es la diferencia entre el mayor y el menor de los valores observados. Lo simbolizamos por R

a) Series simples:

$$x_i \quad (i = 1, 2, \dots, n); x_1, x_2, \dots, x_n$$

$x_{\max}$: valor máximo observado

$x_{\min}$: valor mínimo observado

$$R = x_{\max} - x_{\min} \quad R = x_n - x_1 \quad \otimes$$

⊗ Para hacer uso de estas expresiones se deben ordenarse previamente los valores de la variable de menor a mayor

b) Distribuciones de Frecuencias de Variables discretas

$$R = y_{\max} - y_{\min} \quad R = y_m - y_1 \quad \otimes$$

c) Distribuciones de Frecuencias de Variables continuas

$$R = y_{\max} - y_{\min} \quad R = y'_m - y'_0 \quad \otimes$$

Desviación Media El recorrido es una medida posicional de dispersión ya que está basada en las posiciones de ciertos elementos. La desviación media **está basada en todos los elementos y permite medir la dispersión alrededor de un promedio.**

Se define como la media aritmética de las desviaciones con respecto a la media, tomadas en valor absoluto.

El valor de la desviación media se calcula, a veces con la mediana.

a) Series Simples:

$$D.M. = M. [|x_i - \bar{x}|] = \frac{\sum_{i=1}^n |x_i - \bar{x}|}{n}$$

Se ignoran los signos positivos o negativos de la desviaciones ya que como se vio al estudiar las proposiciones de la media,

$$\sum_{i=1}^n |x_i - \bar{x}| = 0$$

b) Distribuciones de frecuencias (variables Discretas y Continuas)

$$D.M. = \frac{\sum_{i=1}^m |y_i - \bar{y}| \cdot n_i}{n}$$

Varianza y Desviación Stándar

Varianza: Medida de los cuadros de las desviaciones con respecto a media aritmética. La simbolizaremos por $V()$, donde, dentro del paréntesis se anotará la variable con la que trabajamos, así

Series Simples: $V(x) = M [(x_i - \bar{x})^2]$

Distribuciones de frecuencias: $V(y) = M [(y_i - \bar{y})^2]$

Propiedades

1 - La varianza es siempre una cantidad no negativa. $V(y) \geq 0$. Es la medida de cantidades no negativas por estar elevada al cuadrado.

2 - La varianza de un constante es 0. $V(k) = 0$ cualquiera sea la constante Si todas las observaciones son iguales (k) la media coincide con el valor común y las desviaciones son todas nulas.

3 - La varianza del producto de una constante por una variable, es igual al producto del cuadrado de la constante por la varianza de la variable. $V(ky) = k^2 \cdot V(y)$.

4 - La varianza de la suma de una variable y una constante es igual a la varianza de la variable. $V(k+y) = V(y)$. Esta propiedad se hace extensiva a la diferencia $V(k-y) = V(y)$.

5 - Si "x" y "y" son dos variables independientes, entonces la varianza de la suma o diferencia, es igual a la suma de las varianzas. $V(x+y) = V(x) + V(y)$ y $V(x-y) = V(x) + V(y)$

- Si "x" y "y" son dos variables dependientes, entonces la varianza de la suma es igual a la suma de las varianzas más dos veces la covarianza de x, y. $V(x+y) = V(x) + V(y) + 2Cov(x,y)$
- y la varianza de la diferencia es igual a la suma de la varianza menos dos veces la covarianza de x, y. $V(x-y) = V(x) + V(y) - 2Cov(x,y)$


Desviación Stándar (Desviación típica o Desviación cuadrática media): valor positivo de la raíz cuadrada de la varianza. **Simbólicamente:** $D.S.(x) = \sigma_x$ (según sea la variable).

Esta medida ha sido definida con el fin de hacer comparable su resultado o valor con los valores de la variable, dado que en el caso de la varianza su valor no es comparable por ser de un orden superior a los valores de la variable, ya que es un promedio de cuadrados. A los fines de reducir dicho valor a la misma dimensión que los valores de la variable, se le extrae la raíz cuadrada y se define la desviación standard.

La desviación se utiliza a los fines de determinar el grado de dispersión de los valores de la variable, con respecto a su valor medio. Ninguna (desviación y Varianza) tiene una interpretación intuitivamente obvia.

Cuando comparemos dos ó más conjuntos de datos cuyas unidades de medición son idénticas, podemos decir que una muestra tiene un menor grado de dispersión que otra, Si la primera tiene una menor varianza, ó desviación estándar. Sin embargo, dudaríamos de hacer una declaración precisa acerca de un conjunto específico de datos cuando se da un valor específico de una u otra medida.

Cuando n es grande y la distribución de las n observaciones es aproximadamente en forma de campana, aproximadamente normal, puede usarse la regla empírica. En este caso las probabilidades están distribuidas alrededor de la media según los porcentajes del gráfico.



Ecuaciones de cálculo

1- Series Simples

$$DS(x) = \sqrt{V(x)} = \sqrt{\frac{\sum_{i=1}^n x_i^2}{n} - \bar{x}^2}$$

2- Distribuciones de Frecuencias

$$DS(y) = \sqrt{V(y)} = \sqrt{\frac{\sum_{i=1}^m y_i^2 \cdot n_i}{n} - \bar{y}^2}$$

Variable Desvío Estandarizada o Tipificada

Simbolizamos por y_i a la variable natural cuya $M(y) = \bar{y}$ y por $y_i - \bar{y}$, a la variable desvío cuya $M(y_i - \bar{y}) = 0$. Vamos a definir ahora a la variable desvío tipificada o estandarizada que simbolizamos y definimos por:

$$z_i = \frac{y_i - \bar{y}}{DS(y)}$$

Nos interesa la posibilidad que existe de llevar todas las distribuciones de distintas variables a una única escala de valores relativos, que por ser tal; es pierden ya sus respectivas unidades de medidas y pasan a ser valores abstractos z_i para todas las variables y como consecuencia podrán ser analizadas con una única distribución de probabilidad, como modelo teórico explicativo, que es la conocida distribución Normal Estandarizada.

Al cociente de un valor aislado de la variable menos la media, dividido por la desviación estándar se llama **PUNTAJE TIPICO**. Es una desviación relativa a la que hemos llamado un desvío estandarizado.

Coefficiente de Variación

Las medidas de dispersión expresadas en valores absolutos son útiles para describir la dispersión de un solo conjunto de valores. Si se comparan dos conjuntos de cifras, los valores absolutos son convenientes sólo si los promedios de los dos conjuntos son aproximadamente del mismo tamaño y las unidades de medidas son iguales.

1 - Cuando los promedios son diferentes, aunque las unidades sean las mismas, la tarea de comparar los grados de dispersión basados en valores absolutos se hace difícil.

$$CV(x) = \frac{DS(x)}{M(x)}$$

Esto es la dispersión relativa o coeficiente de variación.

2 - En algunos casos es necesario compara elementos que pertenecen a distintas distribuciones, las que diferirán generalmente en el valor de la media aritmética, o en la varianza o en ambas. Incluso puede ser necesaria la comparación entre distribuciones expresadas en diferentes unidades. En estos casos es útil el empleo del puntaje típico o puntaje estándar.

FICHA N°28 – Medidas de asimetría y agudeza


FICHA N°29 – Como calcular la Media, mediana y moda

En una distribución de frecuencia simétrica, los valores de la media, mediana y moda son iguales, es decir

$$\bar{x} = M_e = M_d.$$

Una distribución simétrica significa que la clase central tiene la mayor frecuencia y que las frecuencias, arriba de la clase central de la distribución, corresponden exactamente a las frecuencias abajo de la clase central. Si la distribución de frecuencias se muestra mediante una gráfica de barras (histograma) o un gráfico de líneas (polígono), una recta vertical a través del punto medio de clase, de la clase central, puede dividir la gráfica en dos mitades idénticas. **La intersección de la recta vertical y el eje de las x, da los valores de la media, mediana y moda.**

Gráficamente:



Si las frecuencias arriba de la clase modal no son las mismas que las frecuencias abajo de dicha clase, la distribución no es simétrica y los valores de los promedios no son los mismos. Cuando la distribución no es simétrica, el polígono de frecuencias, se tornará asimétrico ya sea hacia el lado derecho sobre la escala de las x (positivamente asimétrica) o hacia el lado izquierdo sobre el eje de las x (negativamente asimétrica).



1 - Asimétrica derecha: La moda es el valor que más frecuentemente se presenta. Ahora bien, la media está afectada por los valores altos de la distribución, y su posición sobre la escala de las x es estirada hacia la derecha o hacia valores más altos de la escala.

La Mediana no es afectada tan grandemente por los valores altos como es la media, puesto que la mediana es el elemento central y divide la curva en dos áreas iguales.

La mediana, aunque mayor que la moda, está entre la moda y la media. La moda está siempre bajo el punto más alto de la curva.

2 - Asimetría Izquierda

La relación de los promedios es la misma, pero en dirección opuesta.



Coefficiente de Asimetría

Se calcula de la siguiente manera: $\alpha_3 = \frac{\mu_3}{\sigma^3}$ y se denomina coeficiente de sesgo.

donde σ es la desviación típica y μ_3 es el tercer momento respecto de la media y se calcula:

$$\mu_3 = \frac{\sum_{i=1}^n (y_i - \bar{y})^3 n_i}{n} = \sum_{i=1}^n (y_i - \bar{y})^3 h_i$$

El coeficiente puede arrojar los siguientes resultados:

1. Igual a 0, que indica simetría
2. Menor a 0, que indica asimetría negativa o asimetría izquierda.
3. Mayor a 0, que indica asimetría positiva o asimetría derecha.

MEDIDAS DE AGUDEZA O CURTOSIS (puntiagudez)

Según se mencionó al inicio de la presente síntesis, se mide el grado de variación, o la velocidad con que sube y baja la distribución de izquierda a derecha. Dicha variación es medida a través del

coeficiente de curtosis. Y se calcula de la siguiente forma: $\alpha_4 = \frac{\mu_4}{\sigma^4}$

donde σ es la desviación típica y μ_4 es el cuarto momento respecto de la media y se calcula:


$$\mu_4 = \frac{\sum_{i=1}^n (y_i - \bar{y})^4 n_i}{n} = \sum_{i=1}^n (y_i - \bar{y})^4 h_i$$

El coeficiente puede arrojar los siguientes resultados:

- 1 - Igual a 0, indica que la curva es mesocúrtica. Como lo indica la fig. Siguiendo en (2). O sea puntiagudez normal.
- 2 - Menor a 0, indica que la curva es Platicúrtica. Como lo indica la fig. Siguiendo en (3). Puntiagudez menor.
- 3 - Mayor a 0, indica que la curva es Leptocúrtica. Como lo indica la fig. Siguiendo en (1). Puntiagudez Mayor.

Considerar que la curva normal tiene un coeficiente de curtosis igual a 3.

Gráficamente:



UNIDAD N°5: Regresión y Correlación

FICHA N°33 – Curvas de ajuste. Regresión


Curva de ajuste

Muy a menudo en la práctica se encuentra que existe una relación entre dos (o más) variables, y se desea expresar esta relación en forma matemática determinando una ecuación que conecte las variables.

Un primer paso es la colección de datos indicando los valores correspondientes de las variables. Por ejemplo, si x e y denotan la estatura y peso de un adulto; entonces una muestra de n individuos resultaría en las estaturas $x_1, x_2, \dots, x_n$ y los pesos correspondientes $y_1, y_2, \dots, y_n$.

El paso siguiente es dibujar los puntos $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ en un sistema de coordenadas rectangulares. El conjunto resultante de puntos se llama a veces diagrama de dispersión.

Del diagrama de dispersión es posible frecuentemente visualizar una curva que se aproxime a los datos. Dicha curva se llama *curva de aproximación*. En la Fig. 8-1, por ejemplo, se observa que los datos se aproximan bien por una recta y decimos que existe una relación lineal entre las variables. Sin embargo, en la Fig. 8-2 aunque existe una relación entre las variables ésta no es una relación lineal y por esto la llamamos *relación no lineal*. En la **Fig. 8-3 parece que no hay ninguna relación entre las variables.**



El problema general de hallar ecuaciones de curvas de aproximación que se ajusten a conjuntos de datos dados se denomina **curva de ajuste**. En la práctica el tipo de ecuación se sugiere frecuentemente del diagrama de dispersión. Así para la Fig. 8-1 podríamos utilizar una recta $y = a + bx$

Mientras que para la Fig. 8-2 ensayaríamos una *curva cuadrática o parabólica*: $y = a + bx + cx^2$

Algunas veces conviene dibujar los diagramas de dispersión en términos de **variables transformadas**.

Regresión

Uno de los propósitos principales de la curva de ajuste es **estimar una de las variables** (la variable dependiente) de la otra (la *variable independiente*). El proceso de estimación se conoce como **regresión**. Si y se va a estimar a partir de x por medio de alguna ecuación la llamamos *ecuación de regresión de y sobre x* y a la curva correspondiente *curva de regresión de y sobre x* .

FICHA N°34 – Método de los mínimos cuadrados. Recta de mínimos cuadrados

Generalmente, **más de una curva de un tipo dado parece ajustar un conjunto de datos**. Para evitar el juicio individual en la construcción de rectas, parábolas, u otras curvas de aproximación, es necesario obtener una definición de la “**mejor recta de ajuste**”, “**mejor parábola de ajuste**”, etc.

Considérese la Fig. 8-4 en la cual los puntos de datos son $(x_1, y_1), \dots, (x_n, y_n)$. Para un valor dado de x , por ejemplo x_1 , habrá una diferencia entre el valor de y_1 y el valor correspondiente determinado de la curva C .


Denotamos esta diferencia por d_1 , que algunas veces se conoce como *desviación*, *error*, o *residuo* y puede ser positivo, negativo o cero. Análogamente, correspondiendo a los valores $x_2, \dots, x_n$ obtenemos las desviaciones $d_2, \dots, d_n$.

Una medida de la “**bondad de ajuste**” de la curva C al conjunto de datos la suministra la cantidad $d_1^2 + d_2^2 + \dots + d_n^2$. Si la suma es pequeña el ajuste es bueno si es grande el ajuste es malo. Por tanto, tomamos la siguiente

Definición: De todas las curvas de aproximación de un conjunto de puntos dados, la curva que tenga la propiedad de que

$$d_1^2 + d_2^2 + \dots + d_n^2 = \text{un mínimo}$$

es la **mejor curva de ajuste**.



Una curva con esta propiedad se dice que **ajusta los datos en el sentido de mínimos cuadrados** y se llama **curva de regresión de mínimos cuadrados** o simplemente **curva de mínimos cuadrados**. Por tanto, una recta con esta propiedad se llama **recta de mínimos cuadrados**, una parábola con esta propiedad se llama **parábola de mínimos cuadrados**, etc.

Se acostumbra a emplear la definición anterior cuando x es la variable independiente, e y es la variable dependiente. Si x es la variable dependiente, la definición se modifica al considerar las desviaciones horizontales en cambio de las verticales, que se reduce al intercambiar los ejes x, y . Estas dos definiciones conducen en general a dos curvas de mínimos cuadrados diferentes. **Al menos se especifique lo contrario consideraremos a y como variable dependiente y a x como la independiente.**

Recta de Mínimos Cuadrados

Empleando la definición anterior podemos demostrar que la recta de mínimos cuadrados de aproximación al conjunto de datos $(x_1, y_1), \dots, (x_n, y_n)$ tiene la ecuación $y = a + bx$

Donde las constantes a y b se determinan solucionando simultáneamente las ecuaciones

$$\sum y = an + b \sum x$$

Que se conocen como las **ecuaciones normales** para la recta de mínimos cuadrados. Obsérvese que por brevedad hemos utilizado $\sum y$, $\sum xy$ en cambio de

$$\sum xy = a \sum x + b \sum x^2 \quad \sum_{j=1}^n y_j, \sum_{j=1}^n x_j y_j.$$

Los valores de a y b obtenidos a partir de las ecuaciones normales están dados por

$$a = \frac{(\sum y)(\sum x^2) - (\sum x)(\sum xy)}{n \sum x^2 - (\sum x)^2}$$

$$b = \frac{n \sum xy - (\sum x)(\sum y)}{n \sum x^2 - (\sum x)^2}$$

El resultado para b también puede escribirse como:

$$b = \frac{\sum (x - \bar{x})(y - \bar{y})}{\sum (x - \bar{x})^2}$$

Aquí, como es común, **una barra indica media**, es decir, $\bar{x} = (\sum x)/n$. Al dividir ambos lados de la primera ecuación normal por n , resulta $\bar{y} = a + b\bar{x}$

Por tanto, si se desea podemos hallar primero b y luego hallar $a = \bar{y} - b\bar{x}$. Esto es equivalente a escribir la recta de mínimos cuadrados como

$$y - \bar{y} = b(x - \bar{x}) \quad \text{ó} \quad y - \bar{y} = \frac{\sum (x - \bar{x})(y - \bar{y})}{\sum (x - \bar{x})^2} (x - \bar{x})$$

El resultado indica que la constante **b**, que es la pendiente de la recta, es la constante fundamental para determinar la recta. También se ve que la recta de mínimos cuadrados pasa a través del punto $(\bar{x}, \bar{y})$, denominado **centroide** o centro de gravedad de los datos.

Las anotaciones anteriores también son válidas para la recta de regresión de x sobre y . Los resultados se obtienen simplemente intercambiando x e y . Así, por ejemplo, la recta de regresión de mínimos cuadrados de x sobre y es:

$$x - \bar{x} = \frac{\sum (x - \bar{x})(y - \bar{y})}{\sum (y - \bar{y})^2} (y - \bar{y})$$

Recta de Mínimos Cuadrados en términos de Varianzas y Covarianzas Muestrales

Las varianzas y covarianzas muestrales de x , y están dadas por

$$s_x^2 = \frac{\sum (x - \bar{x})^2}{n}, \quad s_y^2 = \frac{\sum (y - \bar{y})^2}{n}, \quad s_{xy} = \frac{\sum (x - \bar{x})(y - \bar{y})}{n}$$

En términos de éstas, las rectas de regresión de mínimos cuadrados de y sobre x y de x sobre y pueden escribirse respectivamente como

$$y - \bar{y} = \frac{s_{xy}}{s_x^2} (x - \bar{x})$$

Definimos el **coeficiente de correlación muestral** por:

$$r = \frac{s_{xy}}{s_x s_y}$$

$$x - \bar{x} = \frac{s_{xy}}{s_y^2} (y - \bar{y})$$

Entonces las rectas de regresión pueden escribirse como

$$\frac{y - \bar{y}}{s_y} = r \left(\frac{x - \bar{x}}{s_x} \right),$$

$$\frac{x - \bar{x}}{s_x} = r \left(\frac{y - \bar{y}}{s_y} \right)$$

Es lógico que las dos rectas son diferentes, al menos que $r = \pm 1$, en cuyo caso todos los puntos muestrales están sobre una recta y hay una correlación y regresión lineal perfecta.

Es de interés notar que si las dos rectas de regresión se escriben como $y = a + bx$, $x = c + dy$ respectivamente, entonces $bd = r^2$

FICHA N°35 – Parábola de mínimos cuadrados

La *parábola de mínimos cuadrados* que ajusta un conjunto de puntos muestrales viene dada por $y = a + bx + cx^2$ (1)

Donde a , b , c se determinan las ecuaciones normales

$$\begin{aligned} \sum y &= na + b \sum x + c \sum x^2 \\ \sum xy &= a \sum x + b \sum x^2 + c \sum x^3 \\ \sum x^2 y &= a \sum x^2 + b \sum x^3 + c \sum x^4 \end{aligned}$$

Estas ecuaciones se obtienen formalmente sumando ambos lados de (1) después de multiplicar sucesivamente por 1, x y x^2 respectivamente.

FICHA N°36 – Regresión múltiple. Coeficiente de correlación lineal y generalizado.

Las ideas anteriores también **pueden generalizarse a más variables**. Por ejemplo, si creemos que hay una relación lineal entre una variable dependiente z y dos variables independientes x, y , entonces buscaríamos una ecuación conectando las variables que tenga la forma $z = a + bx + cy$ (2)

Esta se denomina **ecuación de regresión de z sobre x, y** . Si x es la variable dependiente una ecuación semejante se llamaría **ecuación de regresión de x sobre y, z** .

Puesto que (2) **representa un plano en un sistema de coordenadas rectangulares tridimensional se llama con frecuencia plano de regresión**. Para hallar el plano de regresión de mínimos cuadrados determinamos a, b, c en (2) de modo que

$$\begin{aligned} \sum z &= na + b \sum x + c \sum y \\ \sum xz &= a \sum x + b \sum x^2 + c \sum xy \\ \sum yz &= a \sum y + b \sum xy + c \sum y^2 \end{aligned}$$

Estas ecuaciones, llamadas las **ecuaciones normales** correspondientes a (2), se obtienen como resultado de aplicar una definición análoga a lo ya visto. Adviértase que pueden obtenerse formalmente de (2) multiplicado por 1, x , y respectivamente y sumando.

Generalizaciones a más variables, incluyendo ecuaciones lineales y no lineales conducentes a superficies de regresión en espacios tridimensionales y superiores.

Coeficiente de correlación lineal

En otras palabras, r mide *qué tan bien* la recta de regresión de mínimos cuadrados se ajusta a los datos muestrales.

El coeficiente de correlación puede calcularse a partir de

$$r = \frac{s_{xy}}{s_x s_y} = \frac{\sum (x - \bar{x})(y - \bar{y})}{\sqrt{\sum (x - \bar{x})^2} \sqrt{\sum (y - \bar{y})^2}}$$

Fórmula equivalente, que se utiliza en la práctica

$$r = \frac{n \sum xy - (\sum x)(\sum y)}{\sqrt{[n \sum x^2 - (\sum x)^2][n \sum y^2 - (\sum y)^2]}}$$

El coeficiente de correlación lineal **puede ser positivo o negativo**. Si r es positivo y tiende a **aumentar con x** (la **pendiente de la recta de mínimos cuadrados es positiva**) en tanto que si r es negativo y tiende a **disminuir con x** (la **pendiente es negativa**).

A continuación, damos las propiedades del coeficiente de correlación muestral r , pero estas también son válidas para el coeficiente de correlación poblacional ρ .

1. $-1 \leq r \leq 1$. El valor del coeficiente r está entre 1 y menos 1 porque puede probarse que el denominador es más grande (a lo sumo igual) que el numerador.
2. El valor absoluto de r , $|r|$ mide la fuerza de la asociación lineal entre X e Y , a mayor valor absoluto, hay una asociación lineal más fuerte entre X e Y .
3. El caso particular $r = 0$ indica que no hay asociación lineal entre X e Y .
4. El caso $r = 1$ indica asociación lineal perfecta. O sea que los puntos están ubicados sobre una recta de pendiente (o inclinación) positiva.
5. En el caso $r = -1$ tenemos a los puntos ubicados sobre una recta de pendiente negativa (o sea, decreciente).
6. El signo de r indica que hay asociación positiva entre las variables (si $r > 0$); o asociación negativa entre ellas (si $r < 0$).

7. $r = 0,90$ indica que los puntos están ubicados muy cerca de una recta creciente.
8. $r = 0,80$ indica que los puntos están cerca, pero no tanto, de una recta creciente.
9. r no depende de las unidades en que son medidas las variables (milímetros, centímetros, metros o kilómetros, por ejemplo).
10. Los roles de X e Y son simétricos para el cálculo de r .
11. **Cuidado: el coeficiente de correlación es muy sensible a observaciones atípicas.** Hay que hacer siempre un diagrama de dispersión de los datos antes de resumirlos con r . **La sola presencia de una observación atípica** (o de unas pocas observaciones que siguen un patrón raro) **puede hacer que el valor de r resulte, por ejemplo, positivo, cuando en verdad las variables X e Y están negativamente asociadas.** Si vemos el diagrama de dispersión de los datos, ésta (o estas) observación atípica debiera destacarse en su patrón alejado del resto y seremos capaces de detectarla. Si en cambio sólo nos limitamos a calcular el r esta situación podría escapársenos y **podríamos terminar infiriendo un vínculo entre X e Y que es espúreo.**